

Trabajo de Fin de Máster

APRENDIZAJE MULTITAREA PARA DETECCIÓN DE CÁNCER EN MAMOGRAFÍAS

MULTI-TASK LEARNING FOR BREAST CANCER DETECTION IN MAMMOGRAPHIES

Autor: **Fernández Barrill, Íñigo**

Tutores: García Domínguez, Manuel

Inés Armas, Adrián

MÁSTER

**MÁSTER EN CIENCIA DE DATOS Y APRENDIZAJE
AUTOMÁTICO**

ESCUELA DE MÁSTER Y DOCTORADO



**UNIVERSIDAD
DE LA RIOJA**

AÑO ACADÉMICO: 2022/2023

Agradecimientos

Muchas gracias.

Resumen Documental

El cáncer es una de las principales causas de muerte a nivel mundial, en 2020 se diagnosticaron aproximadamente 18,1 millones de casos, y las previsiones estiman un aumento en las próximas dos décadas hasta los 27 millones de casos. De todos los tipos de cáncer, el más común es el de mama, que afecta principalmente a mujeres (Más del 99 % de los casos se producen en mujeres). Este tipo concreto de cáncer, pese a ser muy común, tiene una tasa de mortalidad baja, sin embargo, sus consecuencias son notables. Por eso, una detección temprana es sumamente importante.

En este trabajo se ha decidido centrarse en el cáncer de mama, pues su prevención y detección temprana reduce significativamente el riesgo de la enfermedad. Aunque anteriormente se ha mencionado que tiene una tasa de mortalidad baja, también se ha mencionado que es el más extendido, y en los países occidentales es la primera causa de muerte en mujeres.

Lo que se busca es utilizar un modelo de aprendizaje profundo multi-tarea sobre un conjunto de datos híbrido consistente en mamografías y en datos médicos asociados a las mismas. Con estos datos, se busca detectar cáncer de mama y para ello se utilizarán varios métodos y arquitecturas.

Palabras Clave

- **Cáncer:** Conjunto de enfermedades caracterizadas por el desarrollo de células con anomalías y la capacidad de multiplicarse. Estas células también son capaces de infiltrarse en el tejido corporal y destruirlo.
- **Cáncer de mama:** Es un tipo de cáncer que afecta al revestimiento de los órganos mamarios, principalmente los conductos que transportan la leche desde la mama hasta el pezón y, los órganos que se encargan de producir la leche, llamados lobulillos.
- **Mamografía:** Es una imagen tomada mediante rayos X de la mama.
- **Modelo:** Es toda aquella arquitectura de redes neuronales con la capacidad de extraer información de los datos.

Índice

1. Introducción	3
1.1. Contexto	3
1.2. Objetivo	3
1.3. Estado del Arte	3
1.4. Librerías y herramientas	3
2. Metodología	5
2.1. Conjunto de datos	5
2.2. Estudio del problema	6
3. Evaluación de los modelos	7
3.1. Modelos para imagen	7
3.2. Modelos para datos	7
4. Conclusión	8
5. Bibliografía y Referencias	9
6. Anexos	10

1. Introducción

1.1. Contexto

En los últimos años, se han logrado grandes avances en el campo de la Inteligencia Artificial. En concreto en el campo del Aprendizaje Automático, cada vez se utilizan más las soluciones basadas en Aprendizaje Multitarea. Estas tareas consisten en entrenar un modelo para que realice varias tareas relacionadas entre ellas y de manera simultánea. Al enfocar de esta manera el aprendizaje, el modelo se fija en características que ayudan en común a todas las tareas, lo que resulta en un mejor rendimiento a la realización de esas mismas tareas por separado. También, este procedimiento ayuda a la generalización del modelo, y evita el sobreaprendizaje.

1.2. Objetivo

El objetivo de este trabajo es desarrollar una herramienta de aprendizaje automático para la detección de cáncer en mamografías.

1.3. Estado del Arte

En medicina las técnicas más extendidas para su detección son las mamografías, el uso de ecografías y la resonancia magnética. Si bien estas técnicas aportan información visual, el objetivo de este trabajo es el complementar esa información con datos sobre el paciente y dar una respuesta con más contexto.

Dentro del aprendizaje multitarea el actual estado del arte es Nash-MTL[4], que consigue su eficiencia en la función de ajuste gracias al método que utilizan a la hora de asignar los pesos.

Finalmente, respecto al tipo de modelos más extendidos para labores de detección y predicción son las CNN (Redes Neuronales Convolucionales), RNN (Redes Neuronales Recurrentes) y GAN (Redes Adversarias Generativas).

1.4. Librerías y herramientas

Este trabajo se va a apoyar principalmente en las siguientes librerías:

- FastAI[1]: Orientada a Aprendizaje Automático de alto nivel basada en PyTorch. Es muy utilizada debido a su sencillez y potencia y a que permite realizar todas las tareas necesarias para crear y entrenar los modelos.
- Timm[8]: Proporciona una colección de distintos arquitecturas y modelos preentrenados en PyTorch, para tareas relacionadas principalmente con la visión por computador.

- Pandas[6]: Está orientada al análisis de datos y proporciona estructuras de datos (como el DataFrame) y funciones para tratarlos.

2. Metodología

2.1. Conjunto de datos

El conjunto de datos es el RSNA Screening Mammography Breast Cancer Detection[5], que es un conjunto de datos con lo necesario para desarrollar la herramienta de detección de cáncer de mama. Cuenta con 54.700 imágenes en formato .DICOM. Este formato (Digital Imaging and Communication In Medicine) es el estándar que se utiliza en medicina para la transmisión de imágenes y datos. En el caso de este conjunto, las imágenes son las mamografías y los datos asociados a ellas son el identificador del paciente, el tipo de imagen, el tamaño de la imagen, la fecha de la imagen y muchas otras especificaciones técnicas sobre la imagen.

Asociado a este conjunto de imágenes, hay archivos en .csv con los datos de los pacientes y de las imágenes. Son train.csv, con el conjunto de Entrenamiento (54.700 imágenes), test.csv, con el conjunto de Test (4 imágenes) y sample_submission.csv, con una muestra para la comprobación. Este último archivo viene dado porque el conjunto de datos viene de una competición de Kaggle y se toma como ejemplo para saber cómo se va a corregir al finalizar la competición. En este archivo hay una fila por cada imagen y las columnas definen los siguientes atributos:

- site_id: El identificador del hospital de origen, en el que se realizaron las imágenes y se recogieron los datos.
- patient_id: El identificador del paciente.
- image_id: El identificador de la imagen.
- laterality: Indica si la imagen se ha tomado sobre el pecho izquierdo o sobre el derecho.
- view: Indica la orientación de la imagen. El procedimiento por defecto es capturar dos vistas por cada pecho.
- age: Indica la edad del paciente en años.
- implant: Indica si el paciente tiene implantes de pecho. El hospital con el identificador 1 sólo da información de los implantes a nivel de paciente, no de pecho, por lo que en este caso no se puede determinar con certeza que el implante sea un implante de pecho.
- density: Es una puntuación que indica lo denso que es el tejido del pecho, asignando A para la menor densidad y D para la mayor. Se indica que un tejido más denso puede dificultar el diagnóstico. Sólo para el conjunto de Entrenamiento.
- machine_id: Un identificador para la máquina que sacó la imagen.
- cancer: Es la variable objetivo, indica si el pecho ha dado positivo en cancer o no. Sólo para el conjunto de Entrenamiento.

- biopsy: Indica si una biopsia se ha realizado en el pecho. Sólo para el conjunto de Entrenamiento.
- invasive: En caso de detectar cáncer, indica si el mismo es invasivo o no. Sólo para el conjunto de Entrenamiento.
- BIRADS: Vale 0 si el pecho necesita seguimiento, 1 si el pecho ha dado negativo en cáncer, y 2 si el pecho es normal. Sólo para el conjunto de Entrenamiento.
- prediction_id: El identificador para la fila que se corresponde con la predicción. Sólo se da para el conjunto de Test.
- difficult_negative_case: Tiene valor positivo si el caso fue más difícil de lo habitual. Sólo para el conjunto de Entrenamiento.

Como este trabajo no está orientado a participar en la competición de Kaggle, no se va a tomar en cuenta el archivo `sample_submission.csv`, y se va a obviar el archivo `test.csv`, pues sólo cuenta con 4 entradas, y prácticamente el total del conjunto de datos están en `train.csv`, y éste será el que se usará.

Las imágenes están estructuradas de forma que por cada paciente hay cuatro imágenes, dos por cada pecho (este es el estándar, pero hay algunos pacientes que tienen un número distinto de imágenes). Cada imagen tiene como nombre su identificador en la tabla de datos y están dentro de una carpeta con el identificador del paciente.

El tamaño total del conjunto de datos es de 314,72 GB.

2.2. Estudio del problema

El primer problema que plantea el conjunto de datos es su tamaño. Todo este tamaño viene de las imágenes, que presentan dos características que las hacen especialmente pesadas. La primera es el propio formato, como se ha mencionado antes, el formato `.DICOM` adjunta a las imágenes cierta información, de la que realmente sólo interesa el identificador del paciente. Sin embargo, esta información realmente tampoco es necesaria, pues únicamente con el nombre de la imagen es suficiente para ubicarla. Por lo tanto, no es necesario que la imagen esté en formato `.DICOM`, así que se transforma a `.jpg`. En segundo lugar, las imágenes son de tamaño 2K e incluso 4K, que es un tamaño totalmente desmesurado para modelos de aprendizaje profundo, por lo que el segundo paso es reducir su tamaño. Manteniendo las proporciones generales de las imágenes, se han reducido a un tamaño de 512x640 píxeles. Realizando estas transformaciones el tamaño total del conjunto es de 5,72 GB, lo que lo hace infinitamente más manejable.

3. Evaluación de los modelos

La idea general es entrenar dos modelos distintos, uno para detectar el cáncer de mama en las mamografías y otro para detectarlo con los datos asociados de los .csv. Una vez se tengan ambos modelos, se les asignarán pesos a cada uno para calcular el resultado final.

3.1. Modelos para imagen

Los modelos elegidos son:

- ResNet 50[2].
- EfficientNet B3[7].
- ConvNext[3].
- HrNet w44[10].
- Deit3 base patch 16 384[9].

3.2. Modelos para datos

4. Conclusión

5. Bibliografía y Referencias

Referencias

- [1] *FastAI*. 2016. URL: <https://www.fast.ai/>.
- [2] Kaiming He et al. *Deep Residual Learning for Image Recognition*. 2015. arXiv: 1512.03385 [cs.CV].
- [3] Zhuang Liu et al. *A ConvNet for the 2020s*. 2022. arXiv: 2201.03545 [cs.CV].
- [4] Aviv Navon et al. «Multi-Task Learning as a Bargaining Game». En: *CoRR* abs/2202.01017 (2022). arXiv: 2202.01017. URL: <https://arxiv.org/abs/2202.01017>.
- [5] Radiological Society of North American. *RSNA Screening Mammography Breast Cancer Detection*. 2022. URL: <https://kaggle.com/competitions/rsna-breast-cancer-detection>.
- [6] *Pandas*. 2022. URL: <https://pandas.pydata.org/>.
- [7] Mingxing Tan y Quoc V. Le. *EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks*. 2020. arXiv: 1905.11946 [cs.LG].
- [8] *timm*. 2022. URL: <https://timm.fast.ai/>.
- [9] Hugo Touvron et al. *Training data-efficient image transformers & distillation through attention*. 2021. arXiv: 2012.12877 [cs.CV].
- [10] Jingdong Wang et al. *Deep High-Resolution Representation Learning for Visual Recognition*. 2020. arXiv: 1908.07919 [cs.CV].

6. Anexos