

Trabajo de Fin de Máster

APRENDIZAJE MULTITAREA PARA DETECCIÓN DE CÁNCER EN MAMOGRAFÍAS

MULTI-TASK LEARNING FOR BREAST CANCER DETECTION IN MAMMOGRAPHIES

Autor: **Fernández Barrill, Íñigo**

Tutores: García Domínguez, Manuel
Inés Armas, Adrián

MÁSTER

**MÁSTER EN CIENCIA DE DATOS Y APRENDIZAJE
AUTOMÁTICO**

ESCUELA DE MÁSTER Y DOCTORADO



**UNIVERSIDAD
DE LA RIOJA**

AÑO ACADÉMICO: 2022/2023

Agradecimientos

Muchas gracias.

Resumen Documental

El cáncer es una de las principales causas de muerte a nivel mundial, en 2020 se diagnosticaron aproximadamente 18,1 millones de casos, y las previsiones estiman un aumento en las próximas dos décadas hasta los 27 millones de casos[9]. De todos los tipos de cáncer, el más común es el de mama, que afecta principalmente a mujeres (más del 99 % de los casos se producen en mujeres). Este tipo concreto de cáncer, pese a ser muy común, tiene una tasa de mortalidad baja, sin embargo, sus consecuencias son notables.

En este trabajo se ha decidido centrarse en el cáncer de mama, pues su prevención y detección temprana reduce significativamente el riesgo que presenta esta enfermedad. Aunque anteriormente se ha mencionado que tiene una tasa de mortalidad baja, también se ha mencionado que es el más extendido, y en los países occidentales es la primera causa de muerte en mujeres, la quinta a nivel global[2][1].

Lo que se busca es utilizar un modelo de aprendizaje profundo multi tarea sobre un conjunto de datos que consiste en mamografías y en los datos médicos asociados a las mismas. Con estos datos, se quiere detectar si se padece o no cáncer de mama y para ello se probarán varios métodos y arquitecturas.

Palabras Clave

- **Cáncer:** Conjunto de enfermedades caracterizadas por el desarrollo de células con anomalías y la capacidad de multiplicarse. Estas células también son capaces de infiltrarse en el tejido corporal y destruirlo.
- **Cáncer de mama:** Es un tipo de cáncer que afecta al revestimiento de los órganos mamarios, principalmente el de los conductos que transportan la leche desde la mama hasta el pezón y el de los órganos que se encargan de producir la leche, que se llaman lobulillos.
- **Mamografía:** Es una imagen tomada mediante rayos X de la mama.
- **Modelo:** Es toda aquella arquitectura de Aprendizaje Profundo que cuenta con la capacidad de extraer información de los datos.
- **Modelo Multitarea:** Como su nombre indica, es un modelo que realiza varias tareas a la vez. Se utiliza para resolver varios problemas relacionados de forma que el propio modelo generalice sobre patrones comunes a todas las tareas.
- **Casos** (en cuanto al cáncer de mama):

- Positivo: La persona tiene cáncer de mama.
 - Negativo: La persona no tiene cáncer de mama.
 - Falso positivo: A una persona que no tiene cáncer de mama, se le diagnostica cáncer de mama.
 - Falso negativo: A una persona que tiene cáncer de mama, no se le diagnostica cáncer de mama.
- ***NaN***: (*Not a Number*) Es un valor nulo, que no se puede utilizar.

Índice

1. Introducción	4
1.1. Contexto	4
1.2. Objetivo	4
1.3. Estado del Arte	5
1.4. Librerías y herramientas	5
2. Metodología	7
2.1. Conjunto de datos	7
2.2. Estudio del problema	8
3. Evaluación y tratamiento de los datos	9
3.1. Descripción de los datos	9
3.2. Balanceo de Datos	9
3.2.1. Balanceo por Pacientes	9
3.2.2. Balanceo por Imágenes	9
3.3. Limpieza del conjunto de datos	10
4. Evaluación de los modelos	11
4.1. Modelos para imagen	11
4.1.1. Resultados sobre el conjunto de datos	11
4.1.2. Modelo Multi Tarea	12
4.2. Modelos para datos	14
5. Modelo Final y Resultados	17
6. Conclusión	18
7. Bibliografía y Referencias	19
8. Anexos	20
8.1. Descripción del Conjunto de Datos	20
8.2. Resultados sobre los distintos conjuntos	22
8.3. Ajuste de parámetros para los modelos de datos	23
8.4. Combinación Óptima de variables en el conjunto de datos	25

1. Introducción

1.1. Contexto

En los últimos años, se han logrado grandes avances en el campo de la Inteligencia Artificial. En concreto, en el campo del Aprendizaje Automático, cada vez se utilizan más las soluciones basadas en Aprendizaje Multitarea. Estas tareas consisten en entrenar un modelo para que realice varias tareas relacionadas entre ellas y de manera simultánea. Al enfocar de esta manera el aprendizaje, el modelo aprende de las características comunes a todas las tareas, lo que resulta en un mejor rendimiento en comparación a la realización de esas mismas tareas por separado. También, este procedimiento ayuda a la generalización del modelo, y evita el sobreaprendizaje.

En el ámbito de la medicina, el Aprendizaje Automático también está cada vez más extendido y ha abierto nuevas vías en la investigación de patógenos. Técnicas basadas en este campo se utilizan sobretodo en el diagnóstico (esto engloba la detección y la predicción), ya que un modelo tiene una mayor capacidad para manejar datos y es más eficiente, rápido y preciso a la hora de detectar patologías que un humano. De todas formas, esta tecnología precisa de supervisión humana, y más que un reemplazo, es siempre una herramienta que complementa y mejora el trabajo de las personas.

1.2. Objetivo

Ya que el cáncer de mama es un gran problema para las mujeres en los países occidentales, es muy importante que se estudien y se mejoren los procedimientos para su prevención, detección y tratamiento. También, teniendo en cuenta la situación actual en los hospitales, es necesario que se ayude al personal sanitario a agilizar la atención y mejorar su calidad.

Por ello, el objetivo de este trabajo es desarrollar una herramienta de Aprendizaje Automático para el diagnóstico de cáncer en mamografías mediante el uso de una arquitectura basada en un modelo multi tarea. Dicho de otra manera, el objetivo es realizar una clasificación para distinguir aquellas instancias que presentan cáncer de mama de las que no.

Finalmente, hay que tener en cuenta que debe haber un equilibrio a la hora de realizar el diagnóstico, pues si un caso positivo no se diagnostica, las consecuencias son graves, desde la muerte de la persona hasta un tratamiento más complicado al haber detectado la enfermedad en un estado más avanzado. En caso contrario, si se emite un falso positivo, también puede ser muy perjudicial, pues los tratamientos pueden ser caros e invasivos, además de las posibles secuelas que éstos tratamientos puedan dejar en la persona.

1.3. Estado del Arte

En medicina las técnicas más extendidas para la detección del cáncer de mama son las mamografías, el uso de ecografías y la resonancia magnética. Si bien estas técnicas aportan información visual, el objetivo de este trabajo es el complementar esa información con datos sobre el paciente y dar una respuesta con más contexto. También en un grado menos técnico, otra de las formas más comunes para su detección es el examen periódico de las mamas mediante el uso del tacto, sin embargo, aunque esto sirva para detectar cambios que puedan estar provocados por un cáncer de mama, no se ha podido demostrar que realizar este tipo de pruebas de manera recurrente disminuya el riesgo de morir por esta enfermedad.

Dentro del aprendizaje multitarea, el actual estado del arte es *Nash-MTL*[6], que consigue su eficiencia en la función de ajuste gracias al método que utilizan a la hora de asignar los pesos, basándose en juegos de negociación en los cuales las tareas se comparten información y en base a ella, llegan a un acuerdo en el que se reparten los pesos para optimizar los resultados.

Finalmente, respecto al tipo de modelos más extendidos para labores de clasificación de imagen son las *CNN* (Redes Neuronales Convolucionales), *RNN* (Redes Neuronales Recurrentes) y *GAN* (Redes Adversarias Generativas). Todas estas arquitecturas, pese a no ser tan nuevas, siguen siendo las más utilizadas debido al buen rendimiento que ofrecen.

1.4. Librerías y herramientas

Este trabajo se ha realizado en el lenguaje de programación *Python*, que es el más extendido para tareas relacionadas con el Aprendizaje Automático y cuenta con un amplio abanico de librerías especializadas en este campo, concretamente, este trabajo se va a apoyar en las siguientes librerías:

- *FastAI*[3]: Orientada a Aprendizaje Automático de alto nivel basada en *PyTorch*[11]. Es muy utilizada debido a su sencillez y potencia y a que permite realizar todas las tareas necesarias para crear y entrenar los modelos.
- *Timm*[14]: Proporciona una colección de distintos arquitecturas y modelos preentrenados en *PyTorch*[11], para tareas relacionadas principalmente con la visión por computador.
- *NumPy*[8]: Es la librería más utilizada en *Python*, que se basa en el tratamiento de objetos y datos numéricos. Su principal estructura es el *Ndarray*, que a grandes rasgos, es un vector multidimensional.
- *Pandas*[10]: Está orientada al análisis de datos y proporciona estructuras de datos (como el *DataFrame*) y funciones para tratarlos. Un *DataFrame* se compone de un conjunto de *Series*, y se puede comparar con una tabla de datos.
- *Scikit-learn*[12]: Ofrece métricas y herramientas para evaluar los modelos de Aprendizaje Automático.

- *PyTorch*[11]: Está orientada al Aprendizaje Automático y facilita las labores de proceso al implementar lo que se conoce como *Tensor*, que es una estructura multidimensional cuya característica principal es que dentro de una misma dimensión los tensores no tienen por qué tener el mismo tamaño, permitiendo así, entradas de datos irregulares. Está basada en la biblioteca *Torch*[15] de *C*, que ya no se desarrolla, pero sigue siendo importante.

2. Metodología

2.1. Conjunto de datos


El conjunto de datos que se va a utilizar en este trabajo es el *RSNA Screening Mammography Breast Cancer Detection*[7], que tiene lo necesario para desarrollar la herramienta de detección de cáncer de mama. Cuenta con 54.710 imágenes en formato *.DICOM*. Este formato (*Digital Imaging and Communication In Medicine*) es el estándar que se utiliza en medicina para la transmisión de imágenes y datos. En el caso de este conjunto, las imágenes son las mamografías y los datos asociados a ellas son el identificador del paciente, el tipo de imagen, el tamaño de la imagen, la fecha de la imagen y muchas otras especificaciones técnicas sobre la imagen.

Asociado a este conjunto de imágenes, hay archivos en formato *.csv* (*Comma-Separated Values*) con los datos de los pacientes y de las imágenes. Estos archivos son *train.csv*, con el conjunto de Entrenamiento (54.710 imágenes), *test.csv*, con el conjunto de Test (4 imágenes) y *sample_submission.csv*, con una muestra para la comprobación. Este último archivo viene dado porque el conjunto de datos viene de una competición de *Kaggle* y se toma como ejemplo para saber cómo se va a corregir al finalizar la competición. En estos archivos cada fila representa una imagen. Este es un ejemplo de cómo es una fila del conjunto de datos:

site_id	patient_id	image_id	laterality	view	age	cancer	biopsy	invasive	BIRADS	implant	density	machine_id	d_n_c
1	9973	1729524723	R	MLO	43.0	0	0	0	1.0	0	C	49	False

Cuadro 1: Ejemplo de instancia.

También este es un ejemplo de las mamografías sobre las diferentes vistas:



Cuadro 2: Mamografías de ejemplo, según sus vistas.

En el conjunto sólo hay una imagen con la vista *LMO*, y es del pecho derecho, por lo que no hay imagen en esta vista para la mama izquierda en el Cuadro 2. Se puede ver que son

imágenes en escala de grises en donde el fondo aparece en un tono oscuro mientras que la mama se ve porque se resalta en más claro.

Como este trabajo no está orientado a participar en la competición de *Kaggle*, no se va a tomar en cuenta el archivo *sample_submission.csv*, y se va a obviar el archivo *test.csv*, pues sólo cuenta con 4 entradas, y prácticamente el total del conjunto de datos están en *train.csv* (quitando las 4 imágenes del conjunto de test, éste tiene 54.706 imágenes), y éste será el conjunto que se usará de aquí en adelante.

Las imágenes están estructuradas de forma que por cada paciente hay cuatro imágenes, dos por cada pecho (este es el estándar, pero hay algunos pacientes que tienen un número distinto de imágenes). Cada imagen tiene como nombre de archivo su identificador en la tabla de datos y están dentro de una carpeta con el nombre del identificador del paciente.

El tamaño total del conjunto de datos es de 314,72 GB.

2.2. Estudio del problema

El primer problema que plantea el conjunto de datos es su gran tamaño. Todo este volumen viene de las imágenes, que presentan dos características que las hacen especialmente pesadas. La primera es el propio formato, como se ha mencionado antes, el formato *.DICOM* adjunta a las imágenes cierta información, de la que realmente sólo interesa el identificador del paciente. Sin embargo, esta información realmente tampoco es necesaria, pues únicamente con el nombre de la imagen es suficiente para ubicarla dentro del *.csv*. Por lo tanto, no es necesario que la imagen esté en formato *.DICOM*, así que se transforma a *.jpg*. Esta transformación reduce el tamaño total del conjunto de datos a un tercio del volumen original.

En segundo lugar, las imágenes son de tamaño 2K e incluso 4K. Los modelos de aprendizaje profundo suelen utilizar tamaños de imagen más pequeños, por lo que el segundo paso es reducir la dimensión de las imágenes. Manteniendo las proporciones generales de las imágenes, se han reducido a un tamaño de 512x640 píxeles. Realizando estas transformaciones el tamaño total del conjunto es de 5,72 GB, lo que lo hace mucho más manejable.

3. Evaluación y tratamiento de los datos

Antes de realizar ninguna de las demás tareas, es conveniente entender mejor la composición del conjunto de datos, principalmente de las variables objetivo.

3.1. Descripción de los datos

La información de los datos se puede ver en profundidad en el anexo 8.1. El foco está sobre la principal variable objetivo, que es la variable ‘*cancer*’. Esta variable no está distribuida de manera equilibrada entre las clases, ya que, como se puede ver en el anexo mencionado, solamente el 2 % de las imágenes tienen cáncer. Por lo que es necesario realizar un balanceo.

3.2. Balanceo de Datos

Hay dos opciones sobre cómo realizar el balanceo de datos. Una forma es hacer este balanceo por pacientes, seleccionar a todos los pacientes que hayan dado positivo en cáncer en alguna de las imágenes y escoger el mismo número de pacientes que hayan dado negativo de manera aleatoria. La otra forma sería hacer el balanceo únicamente por imágenes, seleccionar las 1.158 imágenes positivas en cáncer y escoger el mismo número de imágenes de la clase positiva de manera aleatoria.

3.2.1. Balanceo por Pacientes

En el conjunto de datos hay 486 pacientes que han dado positivo en alguna de sus imágenes. Aplicando esta técnica de balanceo, el resultado final es un conjunto de datos reducido, con 972 pacientes.

El conjunto de las imágenes queda reducido también a 4.584 imágenes, de las cuales 1.158 (25 %) tienen cáncer y 3.426 (75 %) no. Esta opción pese a ser una aproximación más realista, sigue estando desbalanceada, ya que los pacientes que han dado negativo tienen todas sus fotos con resultado negativo, mientras que los pacientes positivos tienen la mitad de sus fotos negativas y la mitad positivas (ya que lo normal es presentar cáncer de mama en un pecho y no en los dos).

3.2.2. Balanceo por Imágenes

En el conjunto de datos hay 1.158 imágenes con cáncer. Tras aplicar el balanceo, quedan un total de 2.305 imágenes, las 1.158 positivas y 1.147 negativas. En este balanceo los pacientes con imágenes negativas tendrán generalmente una única imagen, mientras que aquellos con cáncer tendrán dos (las dos vistas estándar por cada pecho). Esto se aleja del caso real, pero se acerca más a los conjuntos de entrenamiento de modelos de aprendizaje profundo, que

cuentan con conjuntos con balanceos cercanos al 50 % porque son los que mejores resultados dan. Así que este es el conjunto que se va a utilizar de aquí en adelante.

3.3. Limpieza del conjunto de datos

Con el conjunto de datos balanceado, se tienen valores faltantes (*NaN*) en la variable ‘*density*’, que es una variable categórica. Como este es un conjunto de datos real, en medicina los casos similares suelen tener características también parecidas. Es por eso por lo que los valores faltantes se van a imputar mediante el uso de *KNN*, que clasifica las instancias en las 4 categorías de densidad del conjunto teniendo en cuenta los casos que más se le parecen. Para las 2.305 instancias del conjunto balanceado por imágenes, se tienen las siguientes densidades:

- *NaN*: 1.019 (44 %).
- *A*: 116 (5 %).
- *B*: 586 (25 %).
- *C*: 520 (23 %).
- *D*: 64 (3 %).

Tras imputar los valores el conjunto queda de la siguiente manera:

- *A*: 204 (9 %).
- *B*: 1323 (57 %).
- *C*: 708 (31 %).
- *D*: 70 (3 %).

4. Evaluación de los modelos

La idea general es entrenar dos modelos distintos, uno para obtener información de las mamografías y otro para predecir el cáncer con los datos asociados a las mismas de los *.csv*. Una vez se tengan ambos modelos, se les asignarán pesos a cada uno para calcular el resultado final.

4.1. Modelos para imagen

Los modelos elegidos son los siguientes:

- *ResNet 50*[4], que es un modelo basado en arquitectura de Red Neuronal.
- *EficientNet B3*[13], que es un modelo basado en arquitectura de Red Neuronal Convolutiva.
- *ConvNext*[5], que es un modelo basado en arquitectura Transformer.
- *HrNet w44*[17], que es un modelo basado en arquitectura de Red Neuronal.
- *DeiT3 base patch 16 384*[16], que es un modelo basado en arquitectura Transformer.

4.1.1. Resultados sobre el conjunto de datos

Para la evaluación de los distintos modelos sobre las imágenes, se ha probado con el conjunto balanceado por imágenes y los modelos mencionados, modificando el factor de aprendizaje, los callbacks a la hora de entrenar y el número de épocas que se ejecutan. Esta comparación de resultados se realiza mediante tablas, en las que se muestran los mejores valores de cada prueba junto con los minutos tardados en llegar a ella y las épocas transcurridas desde el inicio. También, los resultados se evalúan respecto a la variable ‘*cancer*’, que es la variable objetivo del conjunto de datos. Las métricas usadas son las más comunes: Accuracy, Precision, Recall y F-Score, siendo esta última la más importante debido al tipo de problema, pues es la más usada en el ámbito del diagnóstico médico y es peligroso fallar tanto en casos positivos como negativos. Se entrena durante 30 épocas y con un ratio de aprendizaje de $1e-3$, salvo Resnet50, que como control se le aumenta el número de épocas a 50, en caso de que se produzca sobreaprendizaje.

	<i>Resnet50</i>	<i>EfficientNet</i>	<i>ConvNext</i>	<i>Hrnet</i>	<i>Deit</i>
Accuracy	0,6610	0,5254	0,5876	0,5650	0,6271
Precision	0,5807	0,4444	0,5076	0,4918	0,5584
Recall	0,7200	0,4800	0,8933	0,8000	0,5733
F-Score	0,6429	0,4615	0,6473	0,6091	0,5658
Tiempo (Minutos)	13	0,25	8	11	6
Época	37	0	7	9	19

Cuadro 3: Resultados sobre el conjunto de imágenes balanceado por imágenes.

En el Cuadro 3, el mejor modelo ha sido *ConvNext*, que ha logrado los mejores resultados en el menor número de épocas (Sin tener en cuenta a *EfficientNet*), con un F-Score de 0,6473.

Estas tablas pueden servir para hacerse una idea general del rendimiento de los modelos, pero normalmente, se suelen aplicar callbacks de *Early Stopping*, que si no encuentran una mejora de rendimiento entre las épocas, detienen el entrenamiento. Esto previene el sobreajuste y optimiza el tiempo de entrenamiento. Los resultados son los siguientes.

	<i>Resnet50</i>	<i>EfficientNet</i>	<i>ConvNext</i>	<i>Hrnet</i>	<i>Deit</i>
Accuracy	0,5380	0,4642	0,6117	0,5835	0,6486
Precision	0,5309	0,3478	0,5916	0,60000	0,6486
Recall	0,9667	0,0333	0,8208	0,6000	0,6792
F-Score	0,6854	0,0608	0,6876	0,6000	0,6680
Tiempo (Minutos)	1	1	16	12	9
Época	0	0	7	3	7

Cuadro 4: Resultados sobre el conjunto de imágenes balanceado por imágenes, aplicando *Early Stopping*.

En el Cuadro 4 se ha conseguido un F1-Score de 0,6876, mejor aún que en el Cuadro 3, con 0,6473. De esta manera se han conseguido los mejores resultados con el modelo *ConvNext* y al usar *Early Stopping* además se consigue evitar el sobreajuste.

4.1.2. Modelo Multi Tarea

Los resultados obtenidos son buenos, pero pueden ser mejores. Es por ello por lo que se va a utilizar un modelo multi tarea, de forma que se extraiga más información de las imágenes y se obtenga un modelo más robusto. Estos modelos buscan resolver varias tareas relacionadas a la vez, en vez de usar un modelo para cada tarea individual. Este tipo de modelos generalizan mejor y al aprender las características comunes a las tareas y compartir información entre esas características, mejora los resultados frente a los modelos individuales.

Para crear un modelo multi tarea hay varias aproximaciones. La primera es a partir de varias entradas, predecir una única salida. En este caso sería pasarle al modelo tanto la

imagen de la mamografía como los datos asociados a ella y que realice la clasificación con toda la información. La otra aproximación es pasarle una entrada y que devuelva varias salidas. Para este problema, esto sería pasarle al modelo la mamografía y que a partir de la imagen se devuelvan las predicciones sobre las variables y/o clases de salida.

Teniendo en cuenta los resultados de los apartados anteriores, se va a optar por la segunda aproximación, en la que, además de predecir la variable ‘*cancer*’, también se van a predecir las variables ‘*age*’ y ‘*density*’. La elección de estas variables es bastante obvia, pues son las dos variables que más influyen en el resultado final, pues una densidad elevada puede ser indicativo de cáncer y dificulta su detección, mientras que la edad también influye, pues las probabilidades de padecer la enfermedad aumenta con los años.

Escoger estas variables a priori parece un reto, pues cada una es de un tipo distinto, la variable ‘*age*’ es una variable numérica, la variable ‘*cancer*’ es una variable binaria y la variable ‘*density*’ es una variable categórica. Es por eso por lo que cada una tendrá una métrica distinta y una función de pérdida para cada una.

En cuanto a la métrica, para la variable ‘*age*’ se utilizará la raíz del error cuadrático medio, que para tareas de regresión funciona muy bien. Para la variable ‘*cancer*’ se mantiene el F1-Score, por las mismas razones comentadas con anterioridad. Y para la variable ‘*density*’ la métrica de Accuracy. Para las funciones de pérdida, se usará *MSELossFlat* en la variable numérica y *CrossEntropyLossFlat* en las binarias y categóricas. El valor óptimo de la función *MSELossFlat* es 0, mientras que para *CrossEntropyLossFlat* ese valor es 1. En primera instancia todas las funciones tendrán el mismo peso.

Los resultados de esta arquitectura multi tarea con los distintos modelos se obtiene la siguiente tabla:

	<i>Resnet50</i>	<i>EfficientNet</i>	<i>ConvNext</i>	<i>Hrnet</i>	<i>Deit</i>
rmse_age	0,0347	0,1129	0,0361	-	-
f1_cancer	0,5984	0,5200	0,5678	-	-
acc_density	0,5184	0,5228	0,6486	-	-
Tiempo (Minutos)	10	9	30	-	-
Época	10	6	11	-	-

Cuadro 5: Resultados sobre el conjunto de imágenes balanceado por imágenes sobre una arquitectura Multi Tarea.

En el Cuadro 5 se puede ver que el modelo no tiene ningún problema en predecir la edad, con cualquiera de los modelos probados, respecto al cáncer se obtiene un F1-Score parecido a los modelos individuales, pero ligeramente inferiores (salvo en el caso del modelo ConvNext que de manera individual obtenía un F1-Score cercano al 0,7) y en relación a la densidad el Accuracy no obtiene buenos resultados.

Viendo los resultados, se va a ajustar la función de pérdida, asignando pesos de 0,6 al ajuste del cáncer, 0,3 para la densidad y 0,1 para la edad, que es la que mejor calcula.

También en esta ocasión se van a aplicar los mismos callbacks que se aplicaron en los modelos individuales. Con estos cambios, los resultados finales son:

	<i>Resnet50</i>	<i>EfficientNet</i>	<i>ConvNext</i>	<i>Hrnet</i>	<i>Deit</i>
rmse_age	0,0597	0,0509	0,0454	-	-
f1_cancer	0,5647	0,6057	0,5684	-	-
acc_density	0,5835	0,5814	0,5228	-	-
Tiempo (Minutos)	6	5	7	-	-
Época	6	3	2	-	-

Cuadro 6: Resultados sobre el conjunto de imágenes balanceado por imágenes sobre una arquitectura Multi Tarea con la función de pérdida ajustada y aplicando *Early Stopping*.

Con estos resultados del Cuadro 6, los mejores resultados los da el modelo *EfficientNet*. En este modelo en concreto, mejora en las tres métricas.

4.2. Modelos para datos

Siguiendo con el conjunto balanceado por imágenes, se utilizan los datos asociados a las imágenes y se preparan para entrenar los modelos, que necesitan dos conjuntos, X (con las variables con las que calcular la variable objetivo) e y (con la variable objetivo). Teniendo en cuenta que en el conjunto de datos hay variables que se aportan una vez se ha detectado el cáncer, no serán tomadas en cuenta. Los conjuntos quedan de la siguiente manera:

- X :
 - ‘site_id’.
 - ‘patient_id’.
 - ‘image_id’.
 - ‘laterality’.
 - ‘view’.
 - ‘age’.
 - ‘implant’.
 - ‘density’.
 - ‘machine_id’.
- y :
 - ‘cancer’.

Y se distribuye así:

- 70 % para el conjunto de entrenamiento.
- 10 % para el conjunto de validación.
- 20 % para el conjunto de prueba.

Las variables desechadas en este conjunto son ‘*invasive*’, ‘*biopsy*’, ‘*BIRADS*’ y ‘*difficult_negative_case*’, que son aquellas que en primera instancia sólo aparecían en el conjunto de Entrenamiento.

Para evaluar los datos, los modelos seleccionados son los siguientes:

- *Árbol C4.5*.
- *Árbol CART*.
- *Random Forest*.
- *Regresión Logística*.
- *Red Neuronal*.
- *SVM*.

Los modelos obtienen los siguientes resultados (Los detalles sobre los parámetros de los modelos están en el anexo 8.3):

	<i>Árbol C4.5</i>	<i>Árbol CART</i>	<i>Random Forest</i>	<i>Regresión Logística</i>	<i>Red Neuronal</i>	<i>SVM</i>
Accuracy	0,6000	0,6565	0,7000	0,5043	0,4957	0,4957
F1-Score clase negativa	0,59	0,66	0,69	0,67	0,00	0,00
F1-Score clase positiva	0,61	0,66	0,71	0,00	0,66	0,66

Cuadro 7: Resultados sobre el conjunto de validación con todas las variables.

En el Cuadro 7 el mejor modelo ha sido el *Random Forest*, con un F-Score de 0,70 pero se puede ver que en otros modelos hay clases que no obtienen representación (En los modelos de *Red Neuronal* y *SVM*). Esto puede ser debido a que los datos no están normalizados y se esté dando más peso a las variables con valores más altos. Si se normalizan los datos y se repite la evaluación de los modelos se obtienen los siguientes resultados:

	<i>Árbol C4.5</i>	<i>Árbol CART</i>	<i>Random Forest</i>	<i>Regresión Logística</i>	<i>Red Neuronal</i>	<i>SVM</i>
Accuracy	0,5826	0,6304	0,6696	0,5043	0,6304	0,6304
F1-Score clase negativa	0,59	0,64	0,67	0,58	0,62	0,62
F1-Score clase positiva	0,58	0,63	0,67	0,63	0,64	0,64

Cuadro 8: Resultados sobre el conjunto de validación normalizado con todas las variables.

En el Cuadro 8 el modelo *Random Forest* ha vuelto a dar los mejores resultados, con un F-Score de 0,67, aunque no tan buenos como los obtenidos sin normalizar del Cuadro 7, que obtenía un F-Score de 0,70. Los resultados en los modelos que antes fallaban más han mejorado mucho, mientras que los que antes funcionaban bien, ahora funcionan ligeramente

peor. Esto puede ser porque las variables con los valores más elevados sean las que más importancia tengan a la hora de calcular el resultado. De ser cierto, habría que omitir aquellas variables que generen ruido y que no aporten información relevante. Por eso, se va a volver a evaluar reduciendo el número de variables del conjunto de datos, tal y como se explica en el anexo 8.4. Estos son los resultados en el conjunto de validación

	<i>Árbol C4.5</i>	<i>Árbol CART</i>	<i>Random Forest</i>	<i>Regresión Logística</i>	<i>Red Neuronal</i>	<i>SVM</i>
Accuracy	0,7043	0,7043	0,7043	0,6304	0,5217	0,7087
F1-Score clase negativa	0,71	0,71	0,71	0,60	0,14	0,69
F1-Score clase positiva	0,70	0,70	0,70	0,66	0,67	0,72

Cuadro 9: Resultados sobre el conjunto de validación con las mejores variables.

En el Cuadro 9 el modelo que ha dado mejores resultados es el *SVM*, que supera por muy poco a los *Árboles de Decisión* y al *Random Forest*. Sin embargo, el resultado final depende del conjunto de prueba. Para ello, se añade al conjunto de entrenamiento el de validación, se reentrenan los modelos y se evalúan sobre el de prueba. Estos son los resultados finales:

	<i>Árbol C4.5</i>	<i>Árbol CART</i>	<i>Random Forest</i>	<i>Regresión Logística</i>	<i>Red Neuronal</i>	<i>SVM</i>
Accuracy	0,7056	0,7056	0,7208	0,6429	0,6255	0,6926
F1-Score clase negativa	0,71	0,71	0,72	0,63	0,52	0,68
F1-Score clase positiva	0,70	0,70	0,72	0,65	0,69	0,70

Cuadro 10: Resultados sobre el conjunto de prueba con las mejores variables.

En el Cuadro 10 el mejor modelo (ahora sí con una diferencia notable) es el *Random Forest*, que obtiene los mejores resultados en todas las métricas. Concretamente en F-Score ha obtenido un valor de 0,72. Este es el modelo que se utilizará de aquí en adelante para procesar los datos.

5. Modelo Final y Resultados

6. Conclusión

7. Bibliografía y Referencias

Referencias

- [1] *Cáncer de mama*. 2023. URL: https://es.wikipedia.org/wiki/C%C3%A1ncer_de_mama.
- [2] *Cáncer de mama: Estadísticas*. 2022. URL: <https://www.cancer.net/es/tipos-de-c%C3%A1ncer/c%C3%A1ncer-de-mama/estad%C3%ADsticas>.
- [3] *FastAI*. 2016. URL: <https://www.fast.ai/>.
- [4] Kaiming He et al. *Deep Residual Learning for Image Recognition*. 2015. arXiv: 1512.03385 [cs.CV].
- [5] Zhuang Liu et al. *A ConvNet for the 2020s*. 2022. arXiv: 2201.03545 [cs.CV].
- [6] Aviv Navon et al. «Multi-Task Learning as a Bargaining Game». En: *CoRR* abs/2202.01017 (2022). arXiv: 2202.01017. URL: <https://arxiv.org/abs/2202.01017>.
- [7] Radiological Society of North American. *RSNA Screening Mammography Breast Cancer Detection*. 2022. URL: <https://kaggle.com/competitions/rsna-breast-cancer-detection>.
- [8] *NumPy*. 1995. URL: <https://numpy.org/>.
- [9] Sociedad Española de Oncología Médica (SEOM). *Las cifras del cáncer en España 2020*. Página 6.
- [10] *Pandas*. 2022. URL: <https://pandas.pydata.org/>.
- [11] *PyTorch*. 2017. URL: <https://pytorch.org/>.
- [12] *scikit-learn*. 2010. URL: <https://scikit-learn.org/>.
- [13] Mingxing Tan y Quoc V. Le. *EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks*. 2020. arXiv: 1905.11946 [cs.LG].
- [14] *timm*. 2022. URL: <https://timm.fast.ai/>.
- [15] *Torch*. 2002. URL: <http://torch.ch/>.
- [16] Hugo Touvron et al. *Training data-efficient image transformers & distillation through attention*. 2021. arXiv: 2012.12877 [cs.CV].
- [17] Jingdong Wang et al. *Deep High-Resolution Representation Learning for Visual Recognition*. 2020. arXiv: 1908.07919 [cs.CV].

8. Anexos

8.1. Descripción del Conjunto de Datos

El conjunto de datos representa la información de las imágenes mediante una serie de variables o atributos, siendo éstas y su distribución la siguiente:

- **'site_id'**: El identificador del hospital de origen, en el que se realizaron las imágenes y se recogieron los datos. Hay 2 hospitales distintos desde los que provienen las imágenes.
 - Hospital 1: 29.519 imágenes (54 %).
 - Hospital 2: 25.187 imágenes (46 %).
- **'patient_id'**: El identificador del paciente. En total hay 11.913 pacientes distintos, cada uno con sus imágenes.
- **'image_id'**: El identificador de la imagen. Cada fila del conjunto de datos representa a una imagen. Hay 54.706 imágenes en total, y no hay ninguna repetida.
- **'laterality'**: Indica si la imagen se ha tomado sobre el pecho izquierdo (L) o sobre el derecho (R). Hay casi las mismas imágenes para cada lado.
 - Lado derecho (R): 27.439 imágenes (50 %).
 - Lado izquierdo (L): 27.267 imágenes (50 %).
- **'view'**: Indica la orientación de la imagen. El procedimiento por defecto es capturar dos vistas por cada pecho. Hay dos vistas muy usadas, con números muy parecidos, y otras vistas muy poco usadas. Esto es normal, pues las vistas *MLO* y *CC* son las vistas estándar.
 - *MLO* (Oblicua Mediolateral): 27.903 imágenes (52 %).
 - *CC* (Craneocaudal): 26.765 imágenes (48 %).
 - *AT* (Cola Axilar): 19 imágenes (0 %).
 - *LM* (Lateromedial): 10 imágenes (0 %).
 - *ML* (Mediolateral): 8 imágenes (0 %).
 - *LMO* (Oblicua lateromedial): 1 imagen (0 %).
- **'age'**: Indica la edad del paciente en años. Distribución con forma normal centrada en los 58 años. Las edades varían desde los 26 años hasta los 89.
- **'implant'**: Indica si el paciente tiene implantes de pecho. El hospital con el identificador 1 da la información de los implantes a nivel de paciente, no de pecho, por lo que en este caso no se puede determinar con certeza que el implante sea un implante de pecho. La clase sin implantes tiene 53.229 imágenes (97 %) y la clase con implantes tiene 1.477 imágenes (el 3 % restante).
- **'density'**: Es una puntuación que indica lo denso que es el tejido del pecho, asignando A para la menor densidad y D para la mayor. Se indica que un tejido más denso puede dificultar el diagnóstico. Esta variable sólo aparece en el conjunto de Entrenamiento. Hay 4 clases que siguen una distribución normal:

- *NaN*: Hay bastantes entradas sin valor, concretamente 25.236, lo que representa un 46 % del total.
 - *A*: 3.105 entradas (6 % del total).
 - *B*: 12.651 entradas (23 %).
 - *C*: 12.175 entradas (22 %).
 - *D*: 1.539 entradas (3 %).
- **‘machine_id’**: Un identificador para la máquina que sacó la imagen. Se han usado 10 máquinas para realizar las mamografías.
- Máquina 21: 8.221 imágenes (15 %).
 - Máquina 29: 8.267 imágenes (15 %).
 - Máquina 48: 8.699 imágenes (16 %).
 - Máquina 49: 23.529 imágenes (43 %).
 - Máquina 93: 1.915 imágenes (3,35 %).
 - Máquina 170: 923 imágenes (2 %).
 - Máquina 190: 145 imágenes (0,3 %).
 - Máquina 197: 29 imágenes (0,0005 %).
 - Máquina 210: 1.070 imágenes (2 %).
 - Máquina 216: 1.908 imágenes (3,35 %).
- **‘cancer’**: Es la variable objetivo, indica si el pecho ha dado positivo en cáncer o no. Esta variable sólo aparece en el conjunto de Entrenamiento. La clase negativa (la que no tiene cáncer), tiene 53.548 imágenes (98 %) y la clase positiva tiene 1.158 imágenes (2 %).
- **‘biopsy’**: Indica si una biopsia se ha realizado en el pecho. Esta variable sólo aparece en el conjunto de Entrenamiento. La clase negativa (la que no tiene biopsia) tiene 51.737 imágenes (94,5 %) y la clase positiva tiene 2.969 imágenes (5,5 %).
- **‘invasive’**: En caso de detectar cáncer, indica si el mismo es invasivo o no. Esta variable sólo aparece en el conjunto de Entrenamiento. La clase negativa (sin cáncer invasivo) tiene 53.888 imágenes (98,5 %) y la clase positiva tiene 818 imágenes (1,5 %).
- **‘BIRADS’**: 3 clases.
- *NaN*: 28.420 imágenes sin valor asociado (52 %).
 - 0: El pecho necesita seguimiento en 8.249 imágenes (15 %).
 - 1: El pecho ha dado negativo en cáncer en 15.772 imágenes (29 %).
 - 2: El pecho es normal en 2.265 imágenes (4 %).
- **‘prediction_id’**: El identificador para la fila que se corresponde con la predicción. Esta variable sólo aparece en el conjunto de Test.

- *‘difficult_negative_case’*: Tiene valor positivo si el caso fue más difícil de lo habitual. Esta variable sólo aparece en el conjunto de Entrenamiento. La clase negativa tiene 47.001 entradas (86 %) y la positiva 7.705 (14 %).

Es curioso que haya más imágenes con biopsia que con cáncer, entonces es de suponer que la biopsia se ha realizado antes que la imagen, y puede ser que sean pacientes que hayan tenido cáncer de mama en el pasado, pero que actualmente no lo tienen.

8.2. Resultados sobre los distintos conjuntos

En este apartado se muestran los resultados obtenidos con el resto de conjuntos de datos, siendo estos, el conjunto sin balancear y el balanceado por pacientes, con el objetivo de poder compararlos con los resultados finales.

La primera evaluación se ha realizado con los modelos utilizando los parámetros por defecto y un tamaño de imagen de 256x256 (salvo con *Deit*, ya que el modelo exige una resolución de 384x384). El valor del ratio de aprendizaje es de 1e-2 y se ejecuta durante 10 épocas. El conjunto de datos es el original sin balancear, de 54.706 instancias.

	<i>Resnet50</i>	<i>EfficientNet</i>	<i>ConvNext</i>	<i>Hrnet</i>
Accuracy	0,9773	0,9804	0,9805	0,9765
Precision	0,4375	0,0000	0,5385	0,6250
Recall	0,0574	0,0000	0,0327	0,0193
F-Score	0,1015	0,0000	0,0617	0,0375
Tiempo (Minutos)	81	9	66	98
Época	8	0	7	7

Cuadro 11: Resultados sobre todo el conjunto de imágenes.

En el Cuadro 11 el modelo *Deit*, al usar las imágenes más grandes y ser un modelo más pesado, no se evalúa pues sólo en ejecutar la primera época tarda una hora. Se puede ver que las épocas no son rápidas, tardan más o menos 10 minutos cada una y esto es debido al gran volumen de imágenes que hay. También, los altos valores de Accuracy indican que las predicciones están siendo de la clase negativa, sin detectar las instancias con cáncer, por lo que no está prediciendo realmente si tiene cáncer o no.

Al evaluar sobre el balanceo por pacientes, se tiene un volumen de datos muy inferior al anterior, por lo que los tiempos son bastante inferiores y por tanto, se pueden entrenar más épocas. Se entrena durante 30 épocas y se reduce el ratio de aprendizaje a 1e-3. Concretamente, a *Resnet50*, por haber sido la que mejores resultados ha tenido con el conjunto anterior, se le ha aumentado el número de épocas respecto a los demás para ver si puede alcanzar resultados superiores, aunque esto pueda llevar al sobreajuste.

	<i>Resnet50</i>	<i>ConvNext</i>	<i>Hrnet</i>	<i>Deit</i>
Accuracy	0,7173	0,7620	0,7009	0,7806
Precision	0,4565	0,6016	0,3878	0,5506
Recall	0,5598	0,3156	0,4744	0,4475
F-Score	0,5029	0,4140	0,4268	0,4937
Tiempo (Minutos)	57	40	80	45
Época	37	10	13	19

Cuadro 12: Resultados sobre el conjunto de imágenes balanceado por pacientes.

EfficientNet ha dado error al probar este balanceo no se sabe bien por qué. En general, como se puede ver en el Cuadro 12, los resultados son mucho mejores que en la anterior tabla. *Resnet50* ha vuelto a ser el modelo con mejor F-Score, aunque lo ha sido en una época muy avanzada. El modelo más cercano ha sido *Deit* en casi la mitad de épocas.

Aplicando el callback de *Early Stopping*, se obtienen los siguientes resultados:

	<i>Resnet50</i>	<i>EfficientNet</i>	<i>ConvNext</i>	<i>Hrnet</i>	<i>Deit</i>
Accuracy	0,6758	0,7576	0,7304	0,7413	0,8024
Precision	0,2822	0,3333	0,3603	0,3372	0,6000
Recall	0,2727	0,0622	0,2345	0,1388	0,4019
F-Score	0,2774	0,1048	0,2841	0,1966	0,4814
Tiempo (Minutos)	1	1	12	6	20
Época	0	0	1	0	8

Cuadro 13: Resultados sobre el conjunto de imágenes balanceado por pacientes, aplicando *Early Stopping*.

En el Cuadro 13 se ve que el mejor modelo ha sido *Deit*, pero tiene unos resultados inferiores a los resultados del Cuadro 12.

Ninguno de estos conjuntos obtiene unos resultados que se acerquen a los obtenidos con el conjunto balanceado por imágenes.

8.3. Ajuste de parámetros para los modelos de datos

Para el ajuste por parámetros, en las pruebas se ha utilizado un *param grid*, de forma que se prueban combinaciones entre los valores de los parámetros para buscar el modelo que de el mejor resultado. Para todos los modelos, ya que tienen una parte estocástica, se ha asignado un valor de semilla aleatoria de 0. Para los modelos, estos parámetros son los siguientes:

- **Árbol C4.5.**
 - *criterion* = ‘entropy’. (Valor por defecto del Árbol C4.5)
 - *max_depth* = 5, 10, None.
 - *min_samples_split* = 2, 10, 20.
- **Árbol CART.**

- *criterion* = ‘gini’. (Valor por defecto del *Árbol CART*)
- *max_depth* = 5, 10, None.
- *min_samples_split* = 2, 10, 20.
- ***Random Forest.***
 - *criterion* = ‘gini’, ‘entropy’.
 - *max_features* = ‘sqrt’, ‘log2’, None.
 - *bootstrap* = True, False.
- ***Regresión Logística.***
 - *C* = 0,001, 0,01, 0,1, 1.
- ***Red Neuronal.***
 - *hidden_layer_sizes* = 10, 25, 50, 100.
 - *alpha* = 0,0001, 0,001, 0,01, 0,1.
- ***SVM.***
 - *gamma* = ‘auto’ (Valor por defecto).
 - *decision_function_shape* = ‘ovo’, ‘ovr’.

Los parámetros en cada una de las pruebas se consiguen mediante la evaluación sobre el conjunto de validación. Para el conjunto de datos final, estos son los valores de los parámetros:

- ***Árbol C4.5.***
 - *criterion* = ‘entropy’. (Valor por defecto del *Árbol C4.5*)
 - *max_depth* = None.
 - *min_samples_split* = 2.
- ***Árbol CART.***
 - *criterion* = ‘gini’. (Valor por defecto del *Árbol CART*)
 - *max_depth* = None.
 - *min_samples_split* = 2.
- ***Random Forest.***
 - *criterion* = ‘entropy’.
 - *max_features* = None.
 - *bootstrap* = True.
- ***Regresión Logística.***
 - *C* = 0,01.
- ***Red Neuronal.***
 - *hidden_layer_sizes* = 50.
 - *alpha* = 0,1.
- ***SVM.***
 - *gamma* = ‘auto’ (Valor por defecto).
 - *decision_function_shape* = ‘ovo’.

8.4. Combinación Óptima de variables en el conjunto de datos

Con el objetivo de optimizar el resultado de la búsqueda del mejor conjunto de datos para el modelo, se ha creado una función para calcular todas las posibles combinaciones de variables del conjunto. En las posibles combinaciones está el conjunto vacío, por razones obvias, este conjunto no será utilizado para evaluar.

Es también importante mencionar, que los identificadores no van a ser tomados como variables a la hora de entrenar, ya que, aunque hacer esto mejora bastante los resultados, no tiene sentido, pues no tiene por qué seguir un mismo patrón a la hora de añadir nuevos datos, o lo que es lo mismo, pone en grave peligro la generalización del modelo. De esta manera se evita el sobreajuste.

Antes de realizar ninguna combinación, se evalúan los resultados de los modelos sobre este conjunto sin identificadores.

	<i>Árbol C4.5</i>	<i>Árbol CART</i>	<i>Random Forest</i>	<i>Regresión Logística</i>	<i>Red Neuronal</i>	<i>SVM</i>
Accuracy	0,6609	0,6565	0,6478	0,6304	0,6304	0,6304
F1-Score clase negativa	0,67	0,66	0,64	0,59	0,32	0,63
F1-Score clase positiva	0,65	0,65	0,65	0,66	0,62	0,63

Cuadro 14: Resultados sobre el conjunto de datos sin las variables con identificadores.

En el Cuadro 14 el modelo que mejor resultado ha dado ha sido el *Árbol C4.5*, por lo que as combinaciones y sus resultados se calcularán utilizando este modelo como base:

Variables	Accuracy	F1-Score clase neg	F1-Score clase pos
'laterality'	0,4805	0,48	0,48
'view'	0,4957	0,00	0,66
'age'	0,6126	0,62	0,61
'implant'	0,5043	0,05	0,66
'density'	0,5195	0,24	0,65
'laterality', 'view'	0,4675	0,28	0,58
'laterality', 'age'	0,6039	0,61	0,60
'laterality', 'implant'	0,4847	0,49	0,48
'laterality', 'density'	0,5130	0,47	0,55
'view', 'age'	0,5909	0,60	0,58
'view', 'implant'	0,5022	0,03	0,67
'view', 'density'	0,4957	0,34	0,59
'age', 'implant'	0,6190	0,63	0,61
'age', 'density'	0,7100	0,71	0,71
'implant', 'density'	0,5238	0,25	0,65
'laterality', 'view', 'age'	0,6061	0,63	0,58
'laterality', 'view', 'implant'	0,4847	0,49	0,48
'laterality', 'view', 'density'	0,4935	0,48	0,50
'laterality', 'age', 'implant'	0,6103	0,60	0,62
'laterality', 'age', 'density'	0,6494	0,66	0,63
'laterality', 'implant', 'density'	0,5173	0,48	0,55
'view', 'age', 'implant'	0,5952	0,60	0,59
'view', 'age', 'density'	0,6990	0,70	0,69
'view', 'implant', 'density'	0,5411	0,50	0,58
'age', 'implant', 'density'	0,7100	0,71	0,71
'laterality', 'view', 'age', 'implant'	0,6126	0,62	0,60
'laterality', 'view', 'age', 'density'	0,6429	0,65	0,64
'laterality', 'view', 'implant', 'density'	0,5022	0,49	0,52
'laterality', 'age', 'implant', 'density'	0,6537	0,67	0,64
'view', 'age', 'implant', 'density'	0,6926	0,70	0,68
'laterality', 'view', 'age', 'implant', 'density'	0,6429	0,65	0,63

Cuadro 15: Resultados sobre el conjunto de datos sin las variables con identificadores y las posibles combinaciones de variables.

En el Cuadro 15 se ven algunos resultados interesantes, al estar sin normalizar, la variable 'age' tiene más peso que las demás a la hora de emitir un resultado. Si se normalizan las variables para dar a cada una de ellas el mismo grado de importancia, los resultados son los siguientes:

Variables	Accuracy	F1-Score clase neg	F1-Score clase pos
'laterality'	0,4805	0,48	0,48
'view'	0,4957	0,00	0,66
'age'	0,5779	0,60	0,56
'implant'	0,5043	0,05	0,66
'density'	0,5195	0,24	0,65
'laterality', 'view'	0,4675	0,28	0,58
'laterality', 'age'	0,5736	0,59	0,56
'laterality', 'implant'	0,4847	0,49	0,48
'laterality', 'density'	0,5130	0,47	0,55
'view', 'age'	0,5736	0,60	0,55
'view', 'implant'	0,5022	0,03	0,67
'view', 'density'	0,4957	0,34	0,59
'age', 'implant'	0,5822	0,61	0,55
'age', 'density'	0,5952	0,61	0,58
'implant', 'density'	0,5238	0,25	0,65
'laterality', 'view', 'age'	0,5671	0,59	0,55
'laterality', 'view', 'implant'	0,4847	0,49	0,48
'laterality', 'view', 'density'	0,4935	0,48	0,50
'laterality', 'age', 'implant'	0,5844	0,58	0,59
'laterality', 'age', 'density'	0,5606	0,61	0,50
'laterality', 'implant', 'density'	0,5173	0,48	0,55
'view', 'age', 'implant'	0,5758	0,60	0,55
'view', 'age', 'density'	0,5974	0,61	0,58
'view', 'implant', 'density'	0,5411	0,50	0,58
'age', 'implant', 'density'	0,5952	0,61	0,58
'laterality', 'view', 'age', 'implant'	0,5649	0,57	0,56
'laterality', 'view', 'age', 'density'	0,5693	0,60	0,53
'laterality', 'view', 'implant', 'density'	0,5022	0,49	0,52
'laterality', 'age', 'implant', 'density'	0,5693	0,61	0,52
'view', 'age', 'implant', 'density'	0,5974	0,61	0,58
'laterality', 'view', 'age', 'implant', 'density'	0,5736	0,60	0,54

Cuadro 16: Resultados sobre el conjunto de datos normalizado sin las variables con identificadores y las posibles combinaciones de variables.

En el Cuadro 16 se puede observar que el rendimiento baja respecto al conjunto sin normalizar (Cuadro 15), ya que el valor de la edad, que es la característica más importante del conjunto, y al normalizarlo, pierde fuerza en el resultado final. Si se comparan las filas normalizadas y sin normalizar, se puede ver que aquellas sin la variable 'age' no presentan cambios, mientras que las que sí, pierden en rendimiento.

Como se puede ver, los dos mejores conjuntos son estos:

- $X1$ (Accuracy: 0,7100, F1-Score en clase positiva 0,71 y F1-Score en clase negativa 0,71)
 - *'age'*.
 - *'density'*.
- $X2$ (Accuracy: 0,7100, F1-Score en clase positiva 0,71 y F1-Score en clase negativa 0,71)
 - *'age'*.
 - *'implant'*.
 - *'density'*.

El segundo con una variable más obtiene los mismos resultados. Sin embargo, como se menciona en la descripción del conjunto de datos, los hospitales computan de manera distinta esta variable, pues el hospital *1* apuntaba cualquier tipo de implante, y el hospital *2* apuntaba sólo los implantes en los pechos.

Por esta razón y ya que la diferencia de rendimiento entre ambos es inexistente, el mejor conjunto de datos para el modelo es el que cuenta únicamente con las variables *'age'* y *'density'*.