

Trabajo de Fin de Máster

APRENDIZAJE MULTITAREA PARA DETECCIÓN DE CÁNCER EN MAMOGRAFÍAS

MULTI-TASK LEARNING FOR BREAST CANCER DETECTION IN MAMMOGRAPHIES

Autor: **Fernández Barrill, Íñigo**

Tutores: García Domínguez, Manuel
Inés Armas, Adrián

MÁSTER

**MÁSTER EN CIENCIA DE DATOS Y APRENDIZAJE
AUTOMÁTICO**

ESCUELA DE MÁSTER Y DOCTORADO



**UNIVERSIDAD
DE LA RIOJA**

AÑO ACADÉMICO: 2022/2023

Agradecimientos

Muchas gracias.

Resumen Documental

El cáncer es una de las principales causas de muerte a nivel mundial, en 2020 se diagnosticaron aproximadamente 18,1 millones de casos, y las previsiones estiman un aumento en las próximas dos décadas hasta los 27 millones de casos. De todos los tipos de cáncer, el más común es el de mama, que afecta principalmente a mujeres (más del 99 % de los casos se producen en mujeres). Este tipo concreto de cáncer, pese a ser muy común, tiene una tasa de mortalidad baja, sin embargo, sus consecuencias son notables. Por eso, una detección temprana es sumamente importante.

En este trabajo se ha decidido centrarse en el cáncer de mama, pues su prevención y detección temprana reduce significativamente el riesgo de la enfermedad. Aunque anteriormente se ha mencionado que tiene una tasa de mortalidad baja, también se ha mencionado que es el más extendido, y en los países occidentales es la primera causa de muerte en mujeres.

Lo que se busca es utilizar un modelo de aprendizaje profundo multitarea sobre un conjunto de datos híbrido consistente en mamografías y en datos médicos asociados a las mismas. Con estos datos, se quiere detectar si se padece o no cáncer de mama y para ello se utilizarán varios métodos y arquitecturas.

Palabras Clave

- **Cáncer:** Conjunto de enfermedades caracterizadas por el desarrollo de células con anomalías y la capacidad de multiplicarse. Estas células también son capaces de infiltrarse en el tejido corporal y destruirlo.
- **Cáncer de mama:** Es un tipo de cáncer que afecta al revestimiento de los órganos mamarios, principalmente los conductos que transportan la leche desde la mama hasta el pezón y, los órganos que se encargan de producir la leche, llamados lobulillos.
- **Mamografía:** Es una imagen tomada mediante rayos X de la mama.
- **Modelo:** Es toda aquella arquitectura de redes neuronales con la capacidad de extraer información de los datos.
- **Modelo Multitarea:** Como su nombre indica, es un modelo que realiza varias tareas a la vez. Se utiliza para resolver varios problemas relacionados de forma que el propio modelo generalice sobre patrones comunes a todas las tareas.

Índice

1. Introducción	3
1.1. Contexto	3
1.2. Objetivo	3
1.3. Estado del Arte	3
1.4. Librerías y herramientas	4
2. Metodología	5
2.1. Conjunto de datos	5
2.2. Estudio del problema	6
3. Evaluación y tratamiento de los datos	7
3.1. Descripción de los datos	7
3.2. Balanceo de Datos	9
3.2.1. Balanceo por Pacientes	9
3.2.2. Balanceo por Imágenes	9
3.3. Limpieza del conjunto de datos	9
4. Evaluación de los modelos	10
4.1. Modelos para imagen	10
4.1.1. Resultados sobre el conjunto de datos	10
4.1.2. Modelo Multi Tarea	12
4.2. Modelos para datos	13
5. Modelo Final y Resultados	17
6. Conclusión	18
7. Bibliografía y Referencias	19
8. Anexos	20
8.1. Ajuste de parámetros para los modelos de datos	20
8.2. Combinación Óptima de variables en el conjunto de datos	21

1. Introducción

1.1. Contexto

En los últimos años, se han logrado grandes avances en el campo de la Inteligencia Artificial. En concreto en el campo del Aprendizaje Automático, cada vez se utilizan más las soluciones basadas en Aprendizaje Multitarea. Estas tareas consisten en entrenar un modelo para que realice varias tareas relacionadas entre ellas y de manera simultánea. Al enfocar de esta manera el aprendizaje, el modelo se fija en características que ayudan en común a todas las tareas, lo que resulta en un mejor rendimiento a la realización de esas mismas tareas por separado. También, este procedimiento ayuda a la generalización del modelo, y evita el sobreaprendizaje.

En el ámbito de la medicina, el Aprendizaje Automático también está cada vez más extendido y ha abierto nuevas vías en la investigación de patógenos. Este tipo de técnicas se utilizan sobretodo en el diagnóstico (esto engloba la detección y la predicción), ya que tiene una mayor capacidad para manejar datos y es más eficiente, rápido y preciso a la hora de detectar patologías.

1.2. Objetivo

Ya que el cáncer de mama es un gran problema para las mujeres en los países occidentales, es muy importante que se estudien y se mejoren los procedimientos para su prevención, detección y tratamiento. También, teniendo en cuenta la situación actual en los hospitales, es necesario que se ayude al personal sanitario a agilizar la atención y mejorar su calidad.

Por ello, el objetivo de este trabajo es desarrollar una herramienta de aprendizaje automático para la detección de cáncer en mamografías mediante el uso de una arquitectura basada en un modelo multitarea.

Finalmente, hay que tener en cuenta que debe haber un equilibrio a la hora de realizar el diagnóstico, pues si un caso positivo no se diagnostica, las consecuencias son graves, desde la muerte hasta un tratamiento más costoso al detectarlo en un estado más avanzado. En caso contrario, si se emite un falso positivo, también puede ser muy perjudicial, pues los tratamientos pueden ser caros e invasivos, además de las posibles secuelas que éstos tratamientos puedan dejar.

1.3. Estado del Arte

En medicina las técnicas más extendidas para su detección son las mamografías, el uso de ecografías y la resonancia magnética. Si bien estas técnicas aportan información visual, el objetivo de este trabajo es el complementar esa información con datos sobre el paciente y dar una respuesta con más contexto. También en un grado menos técnico, se recomienda examinar periódicamente de las mamas, mediante el uso del tacto, sin embargo, aunque esto sirva para detectar cambios en las mamas que puedan estar provocados por un cáncer de

mama, no se ha podido demostrar que realizar estas pruebas de manera recurrente disminuya el riesgo de morir por esta patología.

Dentro del aprendizaje multitarea el actual estado del arte es *Nash-MTL*[4], que consigue su eficiencia en la función de ajuste gracias al método que utilizan a la hora de asignar los pesos, basándose en juegos de negociación en los cuales las tareas se comparten información y en base a ella llegan a un acuerdo en el que se reparten los pesos para optimizar los resultados.

Finalmente, respecto al tipo de modelos más extendidos para labores de detección y predicción son las *CNN* (Redes Neuronales Convolucionales), *RNN* (Redes Neuronales Recurrentes) y *GAN* (Redes Adversarias Generativas). Todas estas arquitecturas, pese a no ser tan nuevas, siguen siendo las más utilizadas debido al buen rendimiento que ofrecen.

1.4. Librerías y herramientas

Este trabajo se ha realizado en el lenguaje de programación *Python*, que es el más extendido para tareas relacionadas con el Aprendizaje Automático y cuenta con un amplio abanico de librerías especializadas en este campo, concretamente, este trabajo se va a apoyar en las siguientes librerías:

- *FastAI*[1]: Orientada a Aprendizaje Automático de alto nivel basada en *PyTorch*[8]. Es muy utilizada debido a su sencillez y potencia y a que permite realizar todas las tareas necesarias para crear y entrenar los modelos.
- *Timm*[11]: Proporciona una colección de distintos arquitecturas y modelos preentrenados en *PyTorch*[8], para tareas relacionadas principalmente con la visión por computador.
- *NumPy*[6]: Es la librería más utilizada en *Python*, que se basa en el tratamiento de objetos y datos numéricos. Su principal estructura es el *Ndarray*, que a grandes rasgos, es un vector multidimensional.
- *Pandas*[7]: Está orientada al análisis de datos y proporciona estructuras de datos (como el *DataFrame*) y funciones para tratarlos. Un *DataFrame* se compone de un conjunto de *Series*, y se puede comparar con una tabla de datos.
- *Scikit-learn*[9]: Ofrece métricas y herramientas para evaluar los modelos de Aprendizaje Automático.

2. Metodología

2.1. Conjunto de datos

El conjunto de datos es el *RSNA Screening Mammography Breast Cancer Detection*[5], que es un conjunto de datos con lo necesario para desarrollar la herramienta de detección de cáncer de mama. Cuenta con 54.710 imágenes en formato .DICOM. Este formato (*Digital Imaging and Communication In Medicine*) es el estándar que se utiliza en medicina para la transmisión de imágenes y datos. En el caso de este conjunto, las imágenes son las mamografías y los datos asociados a ellas son el identificador del paciente, el tipo de imagen, el tamaño de la imagen, la fecha de la imagen y muchas otras especificaciones técnicas sobre la imagen.

Asociado a este conjunto de imágenes, hay archivos en .csv con los datos de los pacientes y de las imágenes. Son train.csv, con el conjunto de Entrenamiento (54.710 imágenes), test.csv, con el conjunto de Test (4 imágenes) y sample_submission.csv, con una muestra para la comprobación. Este último archivo viene dado porque el conjunto de datos viene de una competición de *Kaggle* y se toma como ejemplo para saber cómo se va a corregir al finalizar la competición. En este archivo hay una fila por cada imagen y las columnas definen los siguientes atributos:

- ‘site_id’: El identificador del hospital de origen, en el que se realizaron las imágenes y se recogieron los datos.
- ‘patient_id’: El identificador del paciente.
- ‘image_id’: El identificador de la imagen.
- ‘laterality’: Indica si la imagen se ha tomado sobre el pecho izquierdo o sobre el derecho.
- ‘view’: Indica la orientación de la imagen. El procedimiento por defecto es capturar dos vistas por cada pecho. Estos son:
 - Vistas estándar: MLO (Oblicua Mediolateral) y CC (Craniocaudal).
 - Vistas complementarias: AT (Cola Axilar), LM (Lateromedial), ML (Mediolateral), LMO (Oblicua lateromedial).
- ‘age’: Indica la edad del paciente en años.
- ‘implant’: Indica si el paciente tiene implantes de pecho. El hospital con el identificador 1 sólo da información de los implantes a nivel de paciente, no de pecho, por lo que en este caso no se puede determinar con certeza que el implante sea un implante de pecho.
- ‘density’: Es una puntuación que indica lo denso que es el tejido del pecho, asignando A para la menor densidad y D para la mayor. Se indica que un tejido más denso puede dificultar el diagnóstico. Sólo para el conjunto de Entrenamiento.
- ‘machine_id’: Un identificador para la máquina que sacó la imagen.

- ‘cancer’: Es la variable objetivo, indica si el pecho ha dado positivo en cáncer o no. Sólo para el conjunto de Entrenamiento.
- ‘biopsy’: Indica si una biopsia se ha realizado en el pecho. Sólo para el conjunto de Entrenamiento.
- ‘invasive’: En caso de detectar cáncer, indica si el mismo es invasivo o no. Sólo para el conjunto de Entrenamiento.
- ‘BIRADS’: Vale 0 si el pecho necesita seguimiento, 1 si el pecho ha dado negativo en cáncer, y 2 si el pecho es normal. Sólo para el conjunto de Entrenamiento.
- ‘prediction_id’: El identificador para la fila que se corresponde con la predicción. Sólo se da para el conjunto de Test.
- ‘difficult_negative_case’: Tiene valor positivo si el caso fue más difícil de lo habitual. Sólo para el conjunto de Entrenamiento.

Como este trabajo no está orientado a participar en la competición de *Kaggle*, no se va a tomar en cuenta el archivo `sample_submission.csv`, y se va a obviar el archivo `test.csv`, pues sólo cuenta con 4 entradas, y prácticamente el total del conjunto de datos están en `train.csv` (quitando las 4 imágenes del conjunto de train, éste tiene 54.706 imágenes), y éste será el conjunto que se usará.

Las imágenes están estructuradas de forma que por cada paciente hay cuatro imágenes, dos por cada pecho (este es el estándar, pero hay algunos pacientes que tienen un número distinto de imágenes). Cada imagen tiene como nombre su identificador en la tabla de datos y están dentro de una carpeta con el identificador del paciente.

El tamaño total del conjunto de datos es de 314,72 GB.

2.2. Estudio del problema

El primer problema que plantea el conjunto de datos es su tamaño. Todo este tamaño viene de las imágenes, que presentan dos características que las hacen especialmente pesadas. La primera es el propio formato, como se ha mencionado antes, el formato `.DICOM` adjunta a las imágenes cierta información, de la que realmente sólo interesa el identificador del paciente. Sin embargo, esta información realmente tampoco es necesaria, pues únicamente con el nombre de la imagen es suficiente para ubicarla. Por lo tanto, no es necesario que la imagen esté en formato `.DICOM`, así que se transforma a `.jpg`. En segundo lugar, las imágenes son de tamaño 2K e incluso 4K, que es un tamaño totalmente desmesurado para modelos de aprendizaje profundo, por lo que el segundo paso es reducir su tamaño. Manteniendo las proporciones generales de las imágenes, se han reducido a un tamaño de 512x640 píxeles. Realizando estas transformaciones el tamaño total del conjunto es de 5,72 GB, lo que lo hace infinitamente más manejable.

3. Evaluación y tratamiento de los datos

Antes de realizar ninguna de las demás tareas, es conveniente entender mejor la composición del conjunto de datos, principalmente de las variables objetivo.

3.1. Descripción de los datos

- ‘site_id’: Hay 2 hospitales distintos desde los que provienen las imágenes.
 - Hospital 1: 29.519 imágenes (54 %).
 - Hospital 2: 25.187 imágenes (46 %).
- ‘patient_id’: En total hay 11.913 pacientes distintos, cada uno con sus imágenes.
- ‘image_id’: Cada fila del conjunto de datos representa a una imagen. Hay 54.706 imágenes en total, y no hay ninguna repetida.
- ‘laterality’: Hay casi las mismas imágenes para cada lado.
 - Lado derecho: 27.439 imágenes (50 %).
 - Lado izquierdo: 27.267 imágenes (50 %).
- ‘view’: Hay dos vistas muy usadas, con números muy parecidos, y otras vistas muy poco usadas. Esto es normal, pues las vistas estándar son las más usadas.
 - MLO: 27.903 imágenes (52 %).
 - CC: 26.765 imágenes (48 %).
 - AT: 19 imágenes (0 %).
 - LM: 10 imágenes (0 %).
 - ML: 8 imágenes (0 %).
 - LMO: 1 imagen (0 %).
- ‘age’: Distribución con forma normal centrada en los 58 años. Las edades varían desde los 26 años hasta los 89.
- ‘implant’: La clase sin implantes tiene 53.229 imágenes (97 %) y la clase con implantes tiene 1.477 imágenes (el 3 % restante).
- ‘density’: Hay 4 clases que siguen una distribución normal:
 - NaN: Hay bastantes entradas sin valor, concretamente 25.236, lo que representa un 46 % del total.
 - A: La clase que representa menos densidad en las mamografías, tiene 3.105 entradas (6 % del total).

- B: 12.651 entradas (23 %).
 - C: 12.175 entradas (22 %).
 - D: La clase más densa, tiene 1.539 entradas (3 %).
- 'machine_id': Se han usado 10 máquinas para realizar las mamografías.
 - Máquina 21: 8.221 imágenes (15 %).
 - Máquina 29: 8.267 imágenes (15 %).
 - Máquina 48: 8.699 imágenes (16 %).
 - Máquina 49: 23.529 imágenes (43 %).
 - Máquina 93: 1.915 imágenes (3,35 %).
 - Máquina 170: 923 imágenes (2 %).
 - Máquina 190: 145 imágenes (0,3 %).
 - Máquina 197: 29 imágenes (0,0005 %).
 - Máquina 210: 1.070 imágenes (2 %).
 - Máquina 216: 1.908 imágenes (3,35 %).
 - 'cancer': La clase negativa (la que no tiene cáncer), tiene 53.548 imágenes (98 %) y la clase positiva tiene 1.158 imágenes (2 %).
 - 'biopsy': La clase negativa (la que no tiene biopsia) tiene 51.737 imágenes (94,5 %) y la clase positiva tiene 2.969 imágenes (5,5 %).
 - 'invasive': La clase negativa (sin cáncer invasivo) tiene 53.888 imágenes (98,5 %) y la clase positiva tiene 818 imágenes (1,5 %).
 - 'BIRADS': 3 clases.
 - NaN: 28.420 imágenes sin valor asociado (52 %).
 - 0: Necesitan seguimiento 8.249 imágenes (15 %).
 - 1: Negativo en cáncer en 15.772 imágenes (29 %).
 - 2: Normales 2.265 imágenes (4 %).
 - 'difficult_negative_case': La clase negativa tiene 47.001 entradas (86 %) y la positiva 7.705 (14 %).

Es curioso que haya más imágenes con biopsia que con cáncer, entonces es de suponer que la biopsia se ha realizado antes que la imagen, y puede ser que sean pacientes que hayan tenido cáncer de mama en el pasado, pero que actualmente no lo tienen.

También, queda claro que hay un problema en el conjunto de datos, y es que está desbalanceado.

3.2. Balanceo de Datos

Hay dos opciones sobre cómo realizar el balanceo de datos. Una forma es hacer este balanceo por pacientes, coger todos los pacientes que hayan dado positivo en cáncer en alguna imagen y seleccionar el mismo número de pacientes que hayan dado negativo de manera aleatoria. La otra forma sería hacer el balanceo únicamente por imágenes, coger las 1.158 imágenes positivas en cáncer y seleccionar el mismo número de imágenes de la clase positiva de manera aleatoria.

3.2.1. Balanceo por Pacientes

En el conjunto de datos hay 486 pacientes que han dado positivo en alguna de sus imágenes. Aplicando esta técnica de balanceo, el resultado final es un conjunto de datos reducido, con 972 pacientes. El conjunto de las imágenes queda reducido también a 4.584 imágenes, de las cuales 1.158 (25 %) tienen cáncer y 3.426 (75 %) no. Esta opción sigue teniendo un desbalanceo en las imágenes, pero es una aproximación más realista, ya que los pacientes que han dado negativo tienen todas sus fotos con resultado negativo, mientras que los pacientes positivos tienen la mitad de sus fotos negativas y la mitad positivas (ya que lo normal es presentar cáncer de mama en un pecho y no en los dos).

3.2.2. Balanceo por Imágenes

En el conjunto de datos hay 1.158 imágenes con cáncer. Tras aplicar el balanceo, quedan un total de 2.305 imágenes, las 1.158 positivas y 1.147 negativas. En este balanceo los pacientes con imágenes negativas tendrán generalmente una única imagen, mientras que aquellos con cáncer tendrán dos. Esto se aleja del caso real, pero se acerca más a los conjuntos de entrenamiento de modelos de aprendizaje profundo, que cuentan con conjuntos con balanceos cercanos al 50 % porque son los que mejores resultados dan.

3.3. Limpieza del conjunto de datos

Con el conjunto de datos balanceado, se tienen valores faltantes (NaN) en la variable ‘density’, que es una variable categórica. Como este es un conjunto de datos real, en medicina los casos similares suelen tener características también parecidas. Es por eso por lo que los valores faltantes se van a imputar mediante el uso de *KNN*, que clasifica las instancias en las 4 categorías de densidad del conjunto teniendo en cuenta los casos que más se le parecen. Para las 2.305 instancias del balanceo por imágenes, se tienen las siguientes densidades:

- NaN: 1.019 (44 %).
- A: 116 (5 %).
- B: 586 (25 %).

- C: 520 (23 %).
- D: 64 (3 %).

Tras imputar los valores el conjunto queda de la siguiente manera:

- A: 204 (9 %).
- B: 1323 (57 %).
- C: 708 (31 %).
- D: 70 (3 %).

4. Evaluación de los modelos

La idea general es entrenar dos modelos distintos, uno para detectar el cáncer de mama en las mamografías y otro para detectarlo con los datos asociados de los .csv. Una vez se tengan ambos modelos, se les asignarán pesos a cada uno para calcular el resultado final.

4.1. Modelos para imagen

Los modelos elegidos son los siguientes:

- *ResNet 50*[2], que es un modelo basado en arquitectura de Red Neuronal.
- *EficientNet B3*[10], que es un modelo basado en arquitectura de Red Neuronal Convolutiva.
- *ConvNext*[3], que es un modelo basado en arquitectura Transformer.
- *HrNet w44*[13], que es un modelo basado en arquitectura de Red Neuronal.
- *DeiT3 base patch 16 384*[12], que es un modelo basado en arquitectura Transformer.

4.1.1. Resultados sobre el conjunto de datos

Para la evaluación de los distintos modelos sobre las imágenes, se han probado con los balanceos vistos modificando el factor de aprendizaje, los callbacks a la hora de entrenar y el número de épocas que se ejecutan. Esta comparación de resultados se realiza mediante tablas, en las que se muestran los mejores valores de cada prueba junto con los minutos tardados en llegar a ella y las épocas transcurridas desde el inicio. También, los resultados se evalúan respecto a la variable ‘cancer’, que es la variable objetivo del conjunto de datos. Las métricas usadas son las más comunes: Accuracy, Precision, Recall y F-Score, siendo esta

última la más importante debido al tipo de problema, pues es la más usada en el ámbito del diagnóstico.

La primera evaluación se ha realizado con los modelos utilizando los parámetros por defecto y un tamaño de imagen de 256x256 (salvo con *Deit*, ya que el modelo exige una resolución de 384x384). El valor del ratio de aprendizaje es de 1e-2 y se ejecuta durante 10 épocas. También el conjunto de datos es el original sin balancear, de 54.706 instancias.

	<i>Resnet50</i>	<i>EfficientNet</i>	<i>ConvNext</i>	<i>Hrnet</i>	<i>Deit</i>
Accuracy	0,977333	0,980441	0,980532	0,976510	-
Precision	0,437500	0,000000	0,538462	0,625000	-
Recall	0,057377	0,000000	0,032710	0,019305	-
F-Score	0,101449	0,000000	0,061674	0,037453	-
Tiempo	81	9	66	98	60
Época	8	0	7	7	0

Deit, al usar las imágenes más grandes y ser un modelo más pesado, no se evalúa pues sólo en ejecutar la primera época tarda una hora. Se puede ver que las épocas no son rápidas, tardan más o menos 10 minutos cada una y esto es debido al gran volumen de imágenes que hay. También, los altos valores de Accuracy indica que las predicciones están siendo de la clase negativa, sin detectar las instancias con cáncer, por lo que no está prediciendo realmente si tiene cáncer o no).

Al evaluar sobre el primer balanceo (el de los pacientes), se tiene un volumen de datos muy inferior al anterior, por lo que los tiempos serán bastante inferiores y por tanto, se pueden entrenar más épocas. Se entrena durante 30 épocas y se reduce el ratio de aprendizaje a 1e-3. Concretamente, a *Resnet50*, por haber sido la que mejores resultados ha tenido, se le ha aumentado el número de épocas respecto a los demás, aunque esto pueda llevar al sobreajuste.

	<i>Resnet50</i>	<i>EfficientNet</i>	<i>ConvNext</i>	<i>Hrnet</i>	<i>Deit</i>
Accuracy	0,717249	-	0,762009	0,700873	0,780568
Precision	0,456446	-	0,601562	0,387833	0,550562
Recall	0,559829	-	0,315574	0,474419	0,447489
F-Score	0,502879	-	0,413978	0,426778	0,493703
Tiempo	57	-	40	80	45
Época	37	-	10	13	19

EfficientNet ha dado error al probar este balanceo no se sabe bien por qué, pero los resultados son mucho mejores que en la anterior tabla. *Resnet50* ha vuelto a ser el modelo con mejor F-Score, aunque lo ha sido en una época muy avanzada. El modelo más cercano ha sido *Deit* en casi la mitad de épocas.

Si se evalúa sobre el segundo balanceo (el de las imágenes), se espera una velocidad aún superior a la del primer balanceo, pues hay aproximadamente la mitad de imágenes en este caso. Se evalúa con los mismos parámetros que la anterior tabla.

	<i>Resnet50</i>	<i>EfficientNet</i>	<i>ConvNext</i>	<i>Hrnet</i>	<i>Deit</i>
Accuracy	0,661017	0,525424	0,587571	0,564972	0,627119
Precision	0,580645	0,444444	0,507576	0,491803	0,558442
Recall	0,720000	0,480000	0,893333	0,800000	0,573333
F-Score	0,642867	0,461538	0,647343	0,609137	0,565789
Tiempo	13	0,25	8	11	6
Época	37	0	7	9	19

Son resultados mejores y más rápidos. Se puede apreciar un empeoramiento en la métrica Accuracy, pero en F-Scores ha habido un aumento considerable. En este caso, el mejor modelo ha sido *ConvNext*, que ha logrado los mejores resultados en el menor número de épocas.

Estas tablas pueden servir para hacerse una idea general del rendimiento de los modelos, pero normalmente, se suelen aplicar callbacks de Early Stopping, que si no encuentran una mejora de rendimiento entre las épocas, detienen el entrenamiento. Esto previene el sobreajuste y optimiza el tiempo de entrenamiento. Los resultados con el primer balanceo es el siguiente.

	<i>Resnet50</i>	<i>EfficientNet</i>	<i>ConvNext</i>	<i>Hrnet</i>	<i>Deit</i>
Accuracy	0,675764	0,757642	0,730349	0,741266	0,802402
Precision	0,282178	0,333333	0,360294	0,337209	0,600000
Recall	0,272727	0,062201	0,234450	0,138756	0,401914
F-Score	0,277372	0,104839	0,284058	0,196610	0,481375
Tiempo	1	1	12	6	20
Época	0	0	1	0	8

Y con el segundo balanceo (esta prueba es la que más se aproxima a las pruebas de aprendizaje profundo) se tienen los siguientes resultados.

	<i>Resnet50</i>	<i>EfficientNet</i>	<i>ConvNext</i>	<i>Hrnet</i>	<i>Deit</i>
Accuracy	0,537961	0,464208	0,611714	0,583514	0,648590
Precision	0,530892	0,347826	0,591592	0,6000000	0,648590
Recall	0,966667	0,033333	0,820833	0,600000	0,679167
F-Score	0,685377	0,060837	0,687609	0,600000	0,668033
Tiempo	1	1	16	12	9
Época	0	0	7	3	7

De esta manera se han conseguido los mejores resultados con el modelo *ConvNext* y al usar Early Stopping además se consigue evitar el sobreajuste.

4.1.2. Modelo Multi Tarea

Los resultados obtenidos son buenos, pero pueden ser mejores. Es por ello por lo que se va a utilizar un modelo multi tarea, de forma que se extraiga más información de las imágenes

y se obtenga un modelo más robusto. En este caso además de predecir la variable ‘cancer’, también se van a predecir las variables ‘age’ y ‘density’. La elección de estas variables es bastante obvia, pues son las dos variables que más influyen en el resultado final, pues una densidad elevada puede ser indicativo de cáncer y dificulta su detección, mientras que la edad también influye, pues las probabilidades de padecer la enfermedad aumenta con los años.

Escoger estas variables a priori parece un reto, pues cada una es de un tipo distinto, la variable ‘age’ es una variable numérica, la variable ‘cancer’ es una variable binaria y la variable ‘density’ es una variable categórica. Es por eso por lo que cada una tendrá una métrica distinta y una función de pérdida para cada una.

En cuanto a la métrica, para la variable ‘age’ se utilizará la raíz del error cuadrático medio, que para tareas de regresión funciona muy bien. Para la variable ‘cancer’ se mantiene el f-score, por las mismas razones comentadas con anterioridad. Y para la variable ‘density’ la métrica de Accuracy. Para las funciones de pérdida, se usará *MSELossFlat* en la variable numérica y *CrossEntropyLossFlat* en las binarias y categóricas. El valor óptimo de la función *MSELossFlat* es 0, mientras que para *CrossEntropyLossFlat* ese valor es 1.

Los resultados de esta arquitectura multi tarea con los distintos modelos se obtiene la siguiente tabla:

	<i>Resnet50</i>	<i>EfficientNet</i>	<i>ConvNext</i>	<i>Hrnet</i>	<i>Deit</i>
rmse_age	0,034737	0,112862	0,036121	-	-
f1_cancer	0,598409	0,519946	0,567793	-	-
acc_density	0,518438	0,522777	0,648590	-	-
Tiempo	10	9	30	-	-
Época	10	6	11	-	-

El modelo no tiene ningún problema en predecir la edad, con cualquiera de los modelos probados, respecto al cáncer se obtiene un f-score parecido a los modelos individuales, pero ligeramente inferiores (salvo en el caso del modelo ConvNext que de manera individual obtenía un f-score cercano al 0,7) y en relación a la densidad el Accuracy es mediocre.

4.2. Modelos para datos

Ya que el conjunto de datos que mejores resultados ha dado ha sido el balanceado por imágenes (2.305 instancias), este será el que se va a utilizar para los modelos de datos.

En primer lugar, hay que preparar los datos para entrenar los modelos, que necesitan dos conjuntos, X (con las variables con las que calcular la variable objetivo) e y (con la variable objetivo). Teniendo en cuenta que en el conjunto de datos hay variables que se aportan a posteriori de detectar el cáncer, no serán tomadas en cuenta. Los conjuntos quedan de la siguiente manera:

- X:

- 'site_id'.
 - 'patient_id'.
 - 'image_id'.
 - 'laterality'.
 - 'view'.
 - 'age'.
 - 'implant'.
 - 'density'.
 - 'machine_id'.
- y:
 - 'cancer'.

Y se distribuye así:

- 70 % para el conjunto de entrenamiento.
- 10 % para el conjunto de validación.
- 20 % para el conjunto de prueba.

Las variables desechadas en este conjunto son 'invasive', 'biopsy', 'BIRADS' y 'difficult_negative_case'.

Para evaluar los datos, los modelos seleccionados son los siguientes:

- Árbol C4.5.
- Árbol CART.
- Random Forest.
- Regresión Logística.
- Red Neuronal.
- SVM.

Los modelos obtienen los siguientes resultados (Los detalles sobre los parámetros de los modelos están en el anexo 8.1):

	Árbol C4.5	Árbol CART	Random Forest	Regresión Logística	Red Neuronal	SVM
Accuracy	0,6000	0,6565	0,7000	0,5043	0,4957	0,4957
F1-Score clase negativa	0,59	0,66	0,69	0,67	0,00	0,00
F1-Score clase positiva	0,61	0,66	0,71	0,00	0,66	0,66

El mejor modelo ha sido el Random Forest, pero se puede ver que en otros modelos hay clases que no obtienen representación. Esto puede ser debido a que los datos no están normalizados y se esté dando más peso a las variables con valores más altos. Si se normalizan los datos y se repite la evaluación de los modelos se obtienen los siguientes resultados:

	Árbol C4.5	Árbol CART	Random Forest	Regresión Logística	Red Neuronal	SVM
Accuracy	0,5826	0,6304	0,6696	0,5043	0,6304	0,6304
F1-Score clase negativa	0,59	0,64	0,67	0,58	0,62	0,62
F1-Score clase positiva	0,58	0,63	0,67	0,63	0,64	0,64

El modelo Random Forest ha vuelto a dar los mejores resultados, aunque no tan buenos como los obtenidos sin normalizar. Los resultados en los modelos que antes fallaban más han mejorado mucho, mientras que los que antes funcionaban bien, ahora funcionan ligeramente peor. Esto puede ser porque las variables con los valores más elevados sean las que más importancia tengan a la hora de calcular el resultado. De ser cierto, habría que omitir aquellas variables que generen ruido y que no aporten información relevante. Por eso, se va a volver a evaluar reduciendo el número de variables del conjunto de datos, que toma la siguiente forma:

- X:
 - ‘age’.
 - ‘implant’.
 - ‘density’.
- y:
 - ‘cancer’.

Y obtiene los siguientes resultados con los datos sin normalizar:

	Árbol C4.5	Árbol CART	Random Forest	Regresión Logística	Red Neuronal	SVM
Accuracy	0,6913	0,6913	0,6870	0,6304	0,5913	0,6696
F1-Score clase negativa	0,71	0,71	0,70	0,60	0,53	0,64
F1-Score clase positiva	0,68	0,68	0,67	0,66	0,64	0,69

Y estos, normalizando los datos:

	Árbol C4.5	Árbol CART	Random Forest	Regresión Logística	Red Neuronal	SVM
Accuracy	0,6522	0,6522	0,6348	0,6478	0,6174	0,6043
F1-Score clase negativa	0,68	0,68	0,66	0,61	0,61	0,58
F1-Score clase positiva	0,62	0,62	0,60	0,68	0,62	0,63

Se obtienen buenos resultados, pero los mejores siguen siendo los del Random Forest con el conjunto completo y sin normalizar.

En el anexo 8.2, se explica cuál es la mejor combinación de variables. Con este conjunto final, el resultado de los modelos en el conjunto de validación son los siguientes:

	Árbol C4.5	Árbol CART	Random Forest	Regresión Logística	Red Neuronal	SVM
Accuracy	0,7043	0,7043	0,7043	0,6304	0,5217	0,7087
F1-Score clase negativa	0,71	0,71	0,71	0,60	0,14	0,69
F1-Score clase positiva	0,70	0,70	0,70	0,66	0,67	0,72

En el conjunto de validación, el mejor modelo es el SVM, que supera por muy poco a los Árboles de Decisión y al Random Forest. Sin embargo, el resultado final depende del conjunto de prueba. Para ello, se añade al conjunto de entrenamiento el de validación y se evalúa sobre el de prueba. Estos son los resultados finales:

	Árbol C4.5	Árbol CART	Random Forest	Regresión Logística	Red Neuronal	SVM
Accuracy	0,7056	0,7056	0,7208	0,6429	0,6255	0,6926
F1-Score clase negativa	0,71	0,71	0,72	0,63	0,52	0,68
F1-Score clase positiva	0,70	0,70	0,72	0,65	0,69	0,70

Con estos resultados, el mejor modelo (ahora sí con una diferencia notable) es el Random Forest, que obtiene los mejores resultados en todas las métricas. Este es el modelo que se utilizará de aquí en adelante para procesar los datos.

5. Modelo Final y Resultados

6. Conclusión

7. Bibliografía y Referencias

Referencias

- [1] *FastAI*. 2016. URL: <https://www.fast.ai/>.
- [2] Kaiming He et al. *Deep Residual Learning for Image Recognition*. 2015. arXiv: 1512.03385 [cs.CV].
- [3] Zhuang Liu et al. *A ConvNet for the 2020s*. 2022. arXiv: 2201.03545 [cs.CV].
- [4] Aviv Navon et al. «Multi-Task Learning as a Bargaining Game». En: *CoRR* abs/2202.01017 (2022). arXiv: 2202.01017. URL: <https://arxiv.org/abs/2202.01017>.
- [5] Radiological Society of North American. *RSNA Screening Mammography Breast Cancer Detection*. 2022. URL: <https://kaggle.com/competitions/rsna-breast-cancer-detection>.
- [6] *NumPy*. 1995. URL: <https://numpy.org/>.
- [7] *Pandas*. 2022. URL: <https://pandas.pydata.org/>.
- [8] *PyTorch*. 2017. URL: <https://pytorch.org/>.
- [9] *scikit-learn*. 2010. URL: <https://scikit-learn.org/>.
- [10] Mingxing Tan y Quoc V. Le. *EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks*. 2020. arXiv: 1905.11946 [cs.LG].
- [11] *timm*. 2022. URL: <https://timm.fast.ai/>.
- [12] Hugo Touvron et al. *Training data-efficient image transformers & distillation through attention*. 2021. arXiv: 2012.12877 [cs.CV].
- [13] Jingdong Wang et al. *Deep High-Resolution Representation Learning for Visual Recognition*. 2020. arXiv: 1908.07919 [cs.CV].

8. Anexos

8.1. Ajuste de parámetros para los modelos de datos

Para el ajuste por parámetros, en las pruebas se ha utilizado un param grid, de forma que se prueban combinaciones entre los valores de los parámetros para buscar el modelo que de el mejor resultado. Para todos los modelos, ya que tienen una parte estocástica, se ha asignado un valor de semilla aleatoria de 0. Para los modelos, estos parámetros son los siguientes:

- Árbol C4.5.
 - *criterion* = 'entropy'. (Valor por defecto del Árbol C4.5)
 - *max_depth* = 5, 10, None.
 - *min_samples_split* = 2, 10, 20.
- Árbol CART.
 - *criterion* = 'gini'. (Valor por defecto del Árbol CART)
 - *max_depth* = 5, 10, None.
 - *min_samples_split* = 2, 10, 20.
- Random Forest.
 - *criterion* = 'gini', 'entropy'.
 - *max_features* = 'sqrt', 'log2', None.
 - *bootstrap* = True, False.
- Regresión Logística.
 - *C* = 0,001, 0,01, 0,1, 1.
- Red Neuronal.
 - *hidden_layer_sizes* = 10, 25, 50, 100.
 - *alpha* = 0,0001, 0,001, 0,01, 0,1.
- SVM.
 - *gamma* = 'auto' (Valor por defecto).
 - *decision_function_shape* = 'ovo', 'ovr'.

Los parámetros en cada una de las pruebas se consiguen mediante la evaluación sobre el conjunto de validación. Para el conjunto de datos final, estos son los valores de los parámetros:

- Árbol C4.5.
 - *criterion* = 'entropy'. (Valor por defecto del Árbol C4.5)
 - *max_depth* = None.
 - *min_samples_split* = 2.
- Árbol CART.
 - *criterion* = 'gini'. (Valor por defecto del Árbol CART)
 - *max_depth* = None.
 - *min_samples_split* = 2.
- Random Forest.
 - *criterion* = 'entropy'.
 - *max_features* = None.
 - *bootstrap* = True.
- Regresión Logística.
 - *C* = 0,01.
- Red Neuronal.
 - *hidden_layer_sizes* = 50.
 - *alpha* = 0,1.
- SVM.
 - *gamma* = 'auto' (Valor por defecto).
 - *decision_function_shape* = 'ovo'.

8.2. Combinación Óptima de variables en el conjunto de datos

Con el objetivo de optimizar el resultado de la búsqueda del mejor conjunto de datos para el modelo, se ha creado una función para calcular todas las posibles combinaciones de variables del conjunto. En las posibles combinaciones está el conjunto vacío, por razones obvias, este conjunto no será utilizado para evaluar.

Es también importante mencionar, que los identificadores no van a ser tomados como variables a la hora de entrenar, ya que, aunque hacer esto mejora bastante los resultados, no tiene sentido, pues no tiene por qué seguir un mismo patrón a la hora de añadir nuevos datos, o lo que es lo mismo, pone en grave peligro la generalización del modelo. De esta manera se evita el sobreajuste.

Antes de realizar ninguna combinación, se evalúan los resultados de los modelos sobre este conjunto sin identificadores.

	Árbol C4.5	Árbol CART	Random Forest	Regresión Logística	Red Neuronal	SVM
Accuracy	0,6609	0,6565	0,6478	0,6304	0,6304	0,6304
F1-Score clase negativa	0,67	0,66	0,64	0,59	0,32	0,63
F1-Score clase positiva	0,65	0,65	0,65	0,66	0,62	0,63

El modelo que mejor resultado ha dado ha sido el Árbol C4.5, por lo que as combinaciones y sus resultados se calcularán utilizando este modelo como base:

Variables	Accuracy	F1-Score clase neg	F1-Score clase pos
'laterality'	0,4805	0,48	0,48
'view'	0,4957	0,00	0,66
'age'	0,6126	0,62	0,61
'implant'	0,5043	0,05	0,66
'density'	0,5195	0,24	0,65
'laterality', 'view'	0,4675	0,28	0,58
'laterality', 'age'	0,6039	0,61	0,60
'laterality', 'implant'	0,4847	0,49	0,48
'laterality', 'density'	0,5130	0,47	0,55
'view', 'age'	0,5909	0,60	0,58
'view', 'implant'	0,5022	0,03	0,67
'view', 'density'	0,4957	0,34	0,59
'age', 'implant'	0,6190	0,63	0,61
'age', 'density'	0,7100	0,71	0,71
'implant', 'density'	0,5238	0,25	0,65
'laterality', 'view', 'age'	0,6061	0,63	0,58
'laterality', 'view', 'implant'	0,4847	0,49	0,48
'laterality', 'view', 'density'	0,4935	0,48	0,50
'laterality', 'age', 'implant'	0,6103	0,60	0,62
'laterality', 'age', 'density'	0,6494	0,66	0,63
'laterality', 'implant', 'density'	0,5173	0,48	0,55
'view', 'age', 'implant'	0,5952	0,60	0,59
'view', 'age', 'density'	0,6990	0,70	0,69
'view', 'implant', 'density'	0,5411	0,50	0,58
'age', 'implant', 'density'	0,7100	0,71	0,71
'laterality', 'view', 'age', 'implant'	0,6126	0,62	0,60
'laterality', 'view', 'age', 'density'	0,6429	0,65	0,64
'laterality', 'view', 'implant', 'density'	0,5022	0,49	0,52
'laterality', 'age', 'implant', 'density'	0,6537	0,67	0,64
'view', 'age', 'implant', 'density'	0,6926	0,70	0,68
'laterality', 'view', 'age', 'implant', 'density'	0,6429	0,65	0,63

Se obtienen algunos resultados interesantes, al estar sin normalizar, la variable ‘age’ tiene más peso que las demás a la hora de emitir un resultado. Si se normalizan las variables para dar a cada una de ellas el mismo grado de importancia, los resultados son los siguientes:

Variables	Accuracy	F1-Score clase neg	F1-Score clase pos
‘laterality’	0,4805	0,48	0,48
‘view’	0,4957	0,00	0,66
‘age’	0,5779	0,60	0,56
‘implant’	0,5043	0,05	0,66
‘density’	0,5195	0,24	0,65
‘laterality’, ‘view’	0,4675	0,28	0,58
‘laterality’, ‘age’	0,5736	0,59	0,56
‘laterality’, ‘implant’	0,4847	0,49	0,48
‘laterality’, ‘density’	0,5130	0,47	0,55
‘view’, ‘age’	0,5736	0,60	0,55
‘view’, ‘implant’	0,5022	0,03	0,67
‘view’, ‘density’	0,4957	0,34	0,59
‘age’, ‘implant’	0,5822	0,61	0,55
‘age’, ‘density’	0,5952	0,61	0,58
‘implant’, ‘density’	0,5238	0,25	0,65
‘laterality’, ‘view’, ‘age’	0,5671	0,59	0,55
‘laterality’, ‘view’, ‘implant’	0,4847	0,49	0,48
‘laterality’, ‘view’, ‘density’	0,4935	0,48	0,50
‘laterality’, ‘age’, ‘implant’	0,5844	0,58	0,59
‘laterality’, ‘age’, ‘density’	0,5606	0,61	0,50
‘laterality’, ‘implant’, ‘density’	0,5173	0,48	0,55
‘view’, ‘age’, ‘implant’	0,5758	0,60	0,55
‘view’, ‘age’, ‘density’	0,5974	0,61	0,58
‘view’, ‘implant’, ‘density’	0,5411	0,50	0,58
‘age’, ‘implant’, ‘density’	0,5952	0,61	0,58
‘laterality’, ‘view’, ‘age’, ‘implant’	0,5649	0,57	0,56
‘laterality’, ‘view’, ‘age’, ‘density’	0,5693	0,60	0,53
‘laterality’, ‘view’, ‘implant’, ‘density’	0,5022	0,49	0,52
‘laterality’, ‘age’, ‘implant’, ‘density’	0,5693	0,61	0,52
‘view’, ‘age’, ‘implant’, ‘density’	0,5974	0,61	0,58
‘laterality’, ‘view’, ‘age’, ‘implant’, ‘density’	0,5736	0,60	0,54

Se puede observar que el rendimiento baja respecto al conjunto sin normalizar, ya que el valor de la edad, que es la característica más importante del conjunto, y al normalizarlo,

pierde fuerza en el resultado final. Si se comparan las filas normalizadas y sin normalizar, se puede ver que aquellas sin la variable 'age' no presentan cambios, mientras que las que sí, pierden en rendimiento.

Como se puede ver, los dos mejores conjuntos son estos:

- X1 (Accuracy: 0,7100, F1-Score en clase positiva 0,71 y F1-Score en clase negativa 0,71)
 - 'age'.
 - 'density'.
- X1 (Accuracy: 0,7100, F1-Score en clase positiva 0,71 y F1-Score en clase negativa 0,71)
 - 'age'.
 - 'implant'.
 - 'density'.

El segundo con una variable más obtiene los mismos resultados. Sin embargo, como se menciona en la descripción del conjunto de datos, los hospitales computan de manera distinta esta variable, pues el hospital 1 apuntaba cualquier tipo de implante, y el hospital 2 apuntaba sólo los implantes en los pechos.

Por esta razón y ya que la diferencia de rendimiento entre ambos es inexistente, el mejor conjunto de datos para el modelo es el que cuenta únicamente con las variables 'age' y 'density'.